

Análisis de Correlación Canónica

Análisis de Correlación Canónica

Variables o análisis de correlación canónica (CVA o CCA) estudia relaciones entre dos vectores de variables. (Hotelling 1936)

Se utiliza cuando un conjunto de variables puede dividirse en dos grupos homogéneos (por criterios económicos, demográficos, sociales, etc.), y se desea estudiar la relación entre ambos conjuntos de variables.

Estudia relaciones lineales entre $\mathbf{X} \in \mathbb{R}^k$ y $\mathbf{Y} \in \mathbb{R}^q$.

Análisis de Correlación Canónica

Sea $\mathbf{Z} = (Z_1, \dots, Z_{k+q})^t = \begin{pmatrix} \mathbf{X} \\ \mathbf{Y} \end{pmatrix} \in \mathbb{R}^{k+q}$.

Sea

$$\text{Cov}(\mathbf{Z}) = \mathbf{\Sigma} = \begin{pmatrix} \mathbf{\Sigma}_{11} & \mathbf{\Sigma}_{12} \\ \mathbf{\Sigma}_{21} & \mathbf{\Sigma}_{22} \end{pmatrix}$$

donde $\mathbf{\Sigma}_{11} \in \mathbb{R}^{k \times k}$, $\mathbf{\Sigma}_{22} \in \mathbb{R}^{q \times q}$.

CCA busca reemplazar los vectores $\mathbf{X}$ y $\mathbf{Y}$ por r pares de nuevas variables que sean proyecciones lineales de $\mathbf{X}$ y $\mathbf{Y}$, donde estos pares son rankeados de acuerdo a su correlación.

CCA: Atletas de decatlón

Los datos corresponden a 34 atletas olímpicos de 1988 a los que se les midió 10 variables.

El dataset es `olympic` que esta en la librería `ad4` de R

Las variables utilizadas son los tiempos en 100, 400 y 1500 metros, 100 metros con obstáculos, salto en largo, tiro, salto en alto, lanzamiento de disco, salto con garrocha y jabalina.

En las relativas al running (100, 400, 110, y 1500), bajos puntos corresponden a mejor performance y las otras disciplinas es al revés, entonces en el análisis para una mejor interpretación les vamos a cambiar el signo a este grupo.

CCA: Atletas de decatlón.

Consideramos dos grupos:

- Las actividades que tienen que ver con los brazos **X**: tiro(poid), disco (disq), (perc) pole vault, jabalina (jave)
- Las que tiene que ver con las piernas **Y**: 100, salto en largo (long), salto en alto (haut), 400, obstáculos (110), 1500

¿Qué nos preguntamos?

CCA: Atletas de decatlón.

Consideramos dos grupos:


- Las actividades que tienen que ver con los brazos **X**: tiro(poid), disco (disq), (perc) pole vault, jabalina (jave)
- Las que tiene que ver con las piernas **Y**: 100, salto en largo (long), salto en alto (haut), 400, obstáculos (110), 1500

¿Qué nos preguntamos?

¿Es cierto que aquellos que son mejor con las piernas son mejores con los brazos? ¿O es al revés? ¿Hay una relación entre estos dos grupos?


CCA: Atletas de decatlón.

Mapa de color de las correlaciones.



CCA: Atletas de decatlón.

Mapa de color de las correlaciones.




CCA: Atletas de decatlón.

Mapa de color de las correlaciones.



X correlation



Y correlation



Cross-correlation



Análisis de Correlación Canónica

Supongamos que buscamos solo un par de variables.

Es decir, buscamos α y β direcciones donde proyectar $\mathbf{X}$ e $\mathbf{Y}$ de modo tal de que la correlación entre las proyecciones sea máxima.

La máxima correlación al cuadrado entre cualquier combinación lineal $\alpha^t \mathbf{X}$ y cualquier combinación lineal $\beta^t \mathbf{Y}$

$$\max_{\alpha \neq \mathbf{0}_p, \beta \neq \mathbf{0}_q} \rho_{\alpha, \beta}^2$$

con

$$\rho_{\alpha, \beta}^2 = \frac{\text{COV}^2(\alpha^t \mathbf{X}, \beta^t \mathbf{Y})}{\text{VAR}(\alpha^t \mathbf{X}) \text{VAR}(\beta^t \mathbf{Y})} = \frac{(\alpha^t \Sigma_{12} \beta)^2}{\alpha^t \Sigma_{11} \alpha \beta^t \Sigma_{22} \beta}$$

Análisis de Correlación Canónica

Llamamos α_1 y β_1 a quienes hacen máxima $\rho_{\alpha,\beta}^2$ y $\rho_1 = \rho_{\alpha_1,\beta_1}$,
 $u_1 = \alpha_1^t \mathbf{X}$ y $v_1 = \beta_1^t \mathbf{Y}$.

¿Cómo seguimos?

Este procedimiento puede verse como una técnica de reducción de dimensión en la que $\mathbf{X}$ y $\mathbf{Y}$ se reducen a u_1 y v_1 de modo que $\rho_{\alpha,\beta}^2$ sea máxima. Pero, la reducción u_1 de $\mathbf{x}$ puede no ser adecuada.

Análisis de Correlación Canónica

Llamamos α_1 y β_1 a quienes hacen máxima $\rho_{\alpha,\beta}^2$ y $\rho_1 = \rho_{\alpha_1,\beta_1}$,
 $u_1 = \alpha_1^t \mathbf{X}$ y $v_1 = \beta_1^t \mathbf{Y}$.

Es decir, este procedimiento puede verse como una técnica de reducción de dimensión en la que $\mathbf{X}$ y $\mathbf{Y}$ se reducen a u_1 y v_1 de modo que $\rho_{\alpha,\beta}^2$ sea máxima.

¿Cómo seguimos?

Buscamos u_2 y v_2 tales que

- $u_2 = \alpha_2^t \mathbf{X}$, $v_2 = \beta_2^t \mathbf{Y}$
- $\rho_2^2 = \text{CORR}^2(u_2, v_2)$ sea máxima en algún sentido y $\rho_1^2 > \rho_2^2$
- u_1, u_2 sean no correlacionados
- v_1, v_2 sean no correlacionados

Análisis de Correlación Canónica

Y así sucesivamente, buscamos $\mathbf{u} = (u_1, \dots, u_m)^t$ y $\mathbf{v} = (v_1, \dots, v_m)$ tales que

- $u_j = \boldsymbol{\alpha}_j^t \mathbf{X}$, $v_j = \boldsymbol{\beta}_j^t \mathbf{Y}$
- $\rho_j^2 = \text{CORR}^2(u_j, v_j)$ sea máxima en algún sentido
 $\rho_1^2 > \rho_2^2 > \dots > \rho_j^2$
- $u_1, \dots, u_m$ sean no correlacionados
- $v_1, \dots, v_m$ sean no correlacionados

Análisis de Correlación Canónica

Y así sucesivamente, buscamos $\mathbf{u} = (u_1, \dots, u_m)^t$ y $\mathbf{v} = (v_1, \dots, v_m)$ tales que

- $u_j = \boldsymbol{\alpha}_j^t \mathbf{X}$, $v_j = \boldsymbol{\beta}_j^t \mathbf{Y}$
- $\rho_j^2 = \text{CORR}^2(u_j, v_j)$ sea máxima en algún sentido
 $\rho_1^2 > \rho_2^2 > \dots > \rho_j^2$
- $u_1, \dots, u_m$ sean no correlacionados
- $v_1, \dots, v_m$ sean no correlacionados

Observemos primero que como hablamos de correlaciones podemos suponer que $\text{VAR}(u_j) = \text{VAR}(v_j) = 1$, es decir,

$$\boldsymbol{\alpha}_j^t \boldsymbol{\Sigma}_{11} \boldsymbol{\alpha}_j = 1 \quad \boldsymbol{\beta}_j^t \boldsymbol{\Sigma}_{22} \boldsymbol{\beta}_j = 1$$

Análisis de Correlación Canónica

Los pares (u_j, v_j) se llaman variables canónicas de $\mathbf{X}$ e $\mathbf{Y}$

Hay dos enfoques para obtener las variables canónicas.

- Maximizando la correlación
- Mínimos cuadrados

CCA: maximizando la correlación

Veamos como podemos obtener α_1 y β_1 . Recordemos que buscamos, maximizar

$\rho_{\alpha,\beta}^2$, sujeto a $\text{VAR}(u_1) = \text{VAR}(v_1) = 1$, es decir, un problema de maximización con restricciones.

$$\rho_{\alpha,\beta}^2 = \text{Cov}^2(\alpha^t \mathbf{X}, \beta^t \mathbf{Y}) = (\alpha^t \Sigma_{12} \beta)^2$$

sujeto a $\alpha^t \Sigma_{11} \alpha = 1$ y $\beta^t \Sigma_{22} \beta = 1$.

Veremos que la solución es

- ρ_1^2 es el máximo autovalor de $\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$

CCA: maximizando la correlación

Veamos como podemos obtener α_1 y β_1 . Recordemos que buscamos, maximizar

$\rho_{\alpha,\beta}^2$, sujeto a $\text{VAR}(u_1) = \text{VAR}(v_1) = 1$, es decir, un problema de maximización con restricciones.

$$\rho_{\alpha,\beta}^2 = \text{Cov}^2(\alpha^t \mathbf{X}, \beta^t \mathbf{Y}) = (\alpha^t \Sigma_{12} \beta)^2$$

sujeto a $\alpha^t \Sigma_{11} \alpha = 1$ y $\beta^t \Sigma_{22} \beta = 1$.

Veremos que la solución es

- ρ_1^2 es el máximo autovalor de $\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$
- α_1 es el autovector de $\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$ asociado a ρ_1^2 tal que $\alpha_1^t \Sigma_{11} \alpha_1 = 1$.

CCA: maximizando la correlación

Veamos como podemos obtener α_1 y β_1 . Recordemos que buscamos, maximizar

$\rho_{\alpha,\beta}^2$, sujeto a $\text{VAR}(u_1) = \text{VAR}(v_1) = 1$, es decir, un problema de maximización con restricciones.

$$\rho_{\alpha,\beta}^2 = \text{Cov}^2(\alpha^t \mathbf{X}, \beta^t \mathbf{Y}) = (\alpha^t \Sigma_{12} \beta)^2$$

sujeto a $\alpha^t \Sigma_{11} \alpha = 1$ y $\beta^t \Sigma_{22} \beta = 1$.

Veremos que la solución es

- ρ_1^2 es el máximo autovalor de $\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$
- α_1 es el autovector de $\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$ asociado a ρ_1^2 tal que $\alpha_1^t \Sigma_{11} \alpha_1 = 1$.
- β_1 es el autovector de $\Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$ asociado a ρ_1^2 tal que $\beta_1^t \Sigma_{22} \beta_1 = 1$.

CCA: maximizando la correlación

Tenemos un problema de maximización que resolveremos usando multiplicadores de Lagrange. teniendo en cuenta que la máxima correlación sera no negativa, consideremos la función:

$$f(\alpha, \beta) = \alpha^t \Sigma_{12} \beta - \frac{\lambda}{2} (\alpha^t \Sigma_{11} \alpha - 1) - \frac{\mu}{2} (\beta^t \Sigma_{22} \beta - 1)$$

siendo λ y μ los multiplicadores de Lagrange. Derivemos

$$\frac{\partial f(\alpha, \beta)}{\partial \alpha} = \Sigma_{12} \beta - \lambda \Sigma_{11} \alpha = 0 \quad (1)$$

$$\frac{\partial f(\alpha, \beta)}{\partial \beta} = \Sigma_{21} \alpha - \mu \Sigma_{22} \beta = 0 \quad (2)$$

$$\frac{\partial f(\alpha, \beta)}{\partial \lambda} = \alpha^t \Sigma_{11} \alpha - 1 = 0 \quad (3)$$

$$\frac{\partial f(\alpha, \beta)}{\partial \mu} = \beta^t \Sigma_{22} \beta - 1 = 0 \quad (4)$$

CCA: maximizando la correlación

Si multiplicamos por izquierda a (1) por α^t y a (2) por β^t queda

$$\begin{aligned}\alpha^t \Sigma_{12} \beta - \lambda \alpha^t \Sigma_{11} \alpha &= 0 \\ \beta^t \Sigma_{21} \alpha - \mu \beta^t \Sigma_{22} \beta &= 0\end{aligned}$$

con lo cual

$$\begin{aligned}\alpha^t \Sigma_{12} \beta - \lambda &= 0 \\ \alpha^t \Sigma_{12} \beta - \mu &= 0\end{aligned}$$

y por lo tanto

$$\alpha^t \Sigma_{12} \beta = \lambda = \mu$$

CCA: maximizando la correlación

Volviendo a (2) y reemplazando a μ por λ queda

$$\Sigma_{21}\alpha - \lambda \Sigma_{22}\beta = 0$$

con lo cual

$$\Sigma_{21}\alpha = \lambda \Sigma_{22}\beta \Rightarrow \beta = \frac{1}{\lambda} \Sigma_{22}^{-1} \Sigma_{21}\alpha$$

Reemplazamos a β en (1) queda

$$\lambda \Sigma_{11}\alpha - \frac{1}{\lambda} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}\alpha = 0$$

y por lo tanto

$$\lambda^2 \Sigma_{11}\alpha = \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}\alpha .$$

CCA: maximizando la correlación

$$\lambda^2 \Sigma_{11} \alpha = \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \alpha .$$

Equivalentemente

$$\lambda^2 \alpha = \Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \alpha = 0$$

luego α es autovector de la matriz de $k \times k$ $\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$ y λ^2 su autovalor.

Como maximizamos, queda claro que $\lambda^2 = \lambda_1^2$, el mayor autovalor y $\alpha = \alpha_1$.

Análogamente, $\beta = \beta_1$ es 1er. autovector de de la matriz de $q \times q$ $\Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$ correspondiente a $\mu^2 = \mu_1^2$, el mayor autovalor.

CCA: maximizando la correlación

- ρ_1 se llama la **primera correlación canónica** entre $\mathbf{X}$ e $\mathbf{Y}$.
- $u_1 = \alpha_1^t \mathbf{X}$, $v_1 = \beta_1^t \mathbf{Y}$ se llaman las **primeras variables canónicas**. Se cumple $\text{VAR}(u_1) = \text{VAR}(v_1) = 1$

Para obtener las r correlaciones restantes, buscamos α_r y β_r tal que $\rho_{\alpha,\beta}^2$, sea máxima sujeto a $\text{VAR}(u_r) = \text{VAR}(v_r) = 1$ y

$$\text{COV}(\alpha_r^t \mathbf{X}, \alpha_j^t \mathbf{X}) = 0 \text{ y } \text{COV}(\beta_r^t \mathbf{Y}, \beta_j^t \mathbf{Y}) = 0 \text{ con } 1 \leq j \leq r-1.$$

Nuevamente tenemos un problema de maximización con restricciones (con más restricciones).

CCA: maximizando la correlación

Dadas (u_1, v_1) , buscamos $u = \alpha^t \mathbf{X}$ y $v = \beta^t \mathbf{Y}$ un segundo par de proyecciones con varianza unitaria que tengan máxima correlación y que sean no correlacionadas con (u_1, v_1) : $\alpha^t \Sigma_{11} \alpha_1 = 0$ y $\beta^t \Sigma_{22} \beta_1 = 0$.

Buscamos maximizar la correlación sujeta a todas estas condiciones. Para ello se puede usar otra vez multiplicadores de Lagrange introduciendo la función

$$\begin{aligned} f(\alpha, \beta) = & (\alpha^t \Sigma_{12} \beta)^2 - \lambda(\alpha^t \Sigma_{11} \alpha - 1) - \mu(\beta^t \Sigma_{22} \beta - 1) \\ & + \eta \alpha^t \Sigma_{11} \alpha_1 + \nu \beta^t \Sigma_{22} \beta_1 \end{aligned}$$

donde λ, μ, η , y ν son multiplicadores de Lagrange.

Derivando e igualando a 0 como antes, tras algunos cálculos llegamos a la solución buscada.

ACC: como un problema de mínimos cuadrados

El problema encontrar las variables canónicas puede ser visto como un problema de minimos cuadrados. Para ello

Sea $\mathbf{A} \in \mathbb{R}^{r \times k}$ y $\mathbf{B} \in \mathbb{R}^{r \times q}$ buscamos $\mathbf{A}$, $\mathbf{B}$ y ν tal que $\mathbf{B}\mathbf{Y} \simeq \nu + \mathbf{A}\mathbf{X}$.

¿¿Parecido??

En el sentido que minimicen

$$E((\mathbf{B}\mathbf{Y} - \nu - \mathbf{A}\mathbf{X})(\mathbf{B}\mathbf{Y} - \nu - \mathbf{A}\mathbf{X})^t)$$

Sujeto a que $\mathbf{A}\Sigma_{11}\mathbf{A}^t = 1$ y $\mathbf{B}\Sigma_{22}\mathbf{B}^t = 1$.

Se puede obtener explícitamente la solución y coincide con el otro enfoque.

Correlación canónica: Propiedades

- las variables canónicas son invariantes por transformaciones lineales: e si $\tilde{\mathbf{X}} = \mathbf{G}\mathbf{X}$ e $\tilde{\mathbf{Y}} = \mathbf{F}\mathbf{Y}$, siendo $\mathbf{G} \in \mathbb{R}^{k \times k}$ y $\mathbf{F} \in \mathbb{R}^{q \times q}$ matrices invertibles, entonces las correlaciones canónicas obtenidas con las matrices de varianzas y covarianzas de estas nuevas variables son idénticas a las de las variables originales. (Sug.: llamemos $\mathbf{V}_X = \Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$ y $\mathbf{V}_Y = \Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$, con autovalores λ^2 y autovectores α y β , usando la notación anterior, respectivamente. Probar que $\mathbf{V}_{\tilde{X}} = \mathbf{G}^t^{-1} \mathbf{V}_X \mathbf{G}^t$ y análogamente $\mathbf{V}_{\tilde{Y}} = \mathbf{F}^t^{-1} \mathbf{V}_Y \mathbf{F}^t$ y comprobar que los autovalores de estas matrices son $\mathbf{G}^t^{-1} \alpha$ y $\mathbf{F}^t^{-1} \beta$. Finalmente, computar $\tilde{u}_j$ y $\tilde{v}_j$. Ver hoja manuscrita)
- Si estandarizamos las variables y trabajamos con las matrices de correlación, las correlaciones canónicas no varían: trabajaremos con las matrices $\mathbf{R}_{11}^{-1} \mathbf{R}_{12} \mathbf{R}_{22}^{-1} \mathbf{R}_{21}$ y $\mathbf{R}_{22}^{-1} \mathbf{R}_{21} \mathbf{R}_{11}^{-1} \mathbf{R}_{12}$ en lugar del producto de las Σ correspondientes.

Correlación canónica: Propiedades

- si $\alpha^t \mathbf{X}$ es una variable canónica también lo será $-\alpha^t \mathbf{X}$. Los signos de las variables canónicas suelen tomarse de manera que las correlaciones entre las variables $\alpha^t \mathbf{X}$ y $\beta^t \mathbf{Y}$ sean positivas.
- Cada correlación canónica al cuadrado, λ_i^2 , es el cuadrado del coeficiente de correlación entre las dos variables canónicas correspondientes.
- La λ_1^2 es mayor o igual que el mayor coeficiente de correlación al cuadrado entre una variable de cada conjunto.
- $\text{COV}(u_i, v_j) = 0$, si $i \neq j$ (Ver hoja manuscrita).

$$\text{COV}(u_i, v_j) = 0, \text{ si } i \neq j$$

• $\text{COV}(u_i, v_j) = 0 \quad i \neq j$

temamos que $Z = \begin{pmatrix} x_1 & x_2 & \dots & x_k \\ y_1 & y_2 & \dots & y_q \end{pmatrix} \quad k > q$

$u = \alpha' X, \quad v = \beta' Y$

• $A = [\alpha_1 \quad \dots \quad \alpha_q \quad \alpha_{q+1} \quad \dots \quad \alpha_k]$

$B = [\beta_1 \quad \dots \quad \beta_q]$

$u = (u_1, \dots, u_k)$

$v = (v_1, \dots, v_q)$

$u = A'X$

$v = B'Y$

temamos que $\Sigma_{AA} = A' A A' = I$

$\Sigma_{VV} = B' \Sigma_{YY} B = I$

• $(\Sigma_{uv})_{ij} = \text{COV}(u_i, v_j) = \alpha_i' \Sigma_{12} \beta_j \quad (1)$

• Vimos en lo deducir que $\beta_j = \sum_{i=1}^q \tilde{\Sigma}_{21}^{-1} \tilde{\Sigma}_{22}^{-1} \alpha_i$

(lo vimos para $j=1$, vale para todos), luego

reemplazando en (1): $\text{COV}(u_i, v_j) = \alpha_i' \sum_{i=1}^q \tilde{\Sigma}_{21}^{-1} \tilde{\Sigma}_{22}^{-1} \tilde{\Sigma}_{21} \alpha_i$

$\text{COV}(u_i, v_j) = \alpha_i' \sum_{i=1}^q \tilde{\Sigma}_{21}^{-1} \tilde{\Sigma}_{22}^{-1} \tilde{\Sigma}_{21} \alpha_i \quad (2)$

Como α_i y $\tilde{\Sigma}_{21}^{-1}$ son autovectores y autovalores, tenemos

$\sum_{i=1}^q \tilde{\Sigma}_{21}^{-1} \tilde{\Sigma}_{22}^{-1} \tilde{\Sigma}_{21} \alpha_i = \tilde{\Sigma}_{21}^{-1} \tilde{\Sigma}_{22}^{-1} \tilde{\Sigma}_{21} \alpha_i$

→ volviendo a (2)

$\text{COV}(u_i, v_j) = \tilde{\Sigma}_{21}^{-1} \tilde{\Sigma}_{22}^{-1} \tilde{\Sigma}_{21} \alpha_i \alpha_j = \begin{cases} \lambda_j & i=j \\ 0 & i \neq j \end{cases}$

CCA para $\tilde{X} = GX$ e $\tilde{Y} = FY$,

Si $\tilde{X} = GX$ y $\tilde{Y} = FY \Rightarrow$ los
 enclavos canónicos de $\tilde{X}$ e $\tilde{Y}$ en los mismos
 que los de X e Y , siendo F, G matrices no
 singulares. (Sean $V_X = \sum_{i=1}^n \tilde{\lambda}_{i2} \tilde{\lambda}_{i1}^{-1} \tilde{\lambda}_{i1}$, idem V_Y)

$$\text{Notemos como queda } V_{\tilde{X}} = \sum_{i=1}^n \tilde{\lambda}_{i1}^{-1} \tilde{\lambda}_{i2} \tilde{\lambda}_{i2}^{-1} \tilde{\lambda}_{i1}$$

$$\tilde{\lambda}_{i1}^{-1} = \lambda_{i1}^{-1} = G \lambda_{i1}^{-1} G^{-1}$$

$$\tilde{\lambda}_{i2} = \lambda_{i2} = F \lambda_{i2} F^{-1}$$

$$\tilde{\lambda}_{i2}^{-1} = G \lambda_{i2}^{-1} F^{-1}, \text{ idem } \tilde{\lambda}_{i1}$$

$$\Rightarrow V_{\tilde{X}} = G^{-1} \tilde{\lambda}_{i1}^{-1} G^{-1} G \lambda_{i1}^{-1} G \tilde{\lambda}_{i2} F^{-1} F \lambda_{i2} F F^{-1} \tilde{\lambda}_{i2}^{-1} G^{-1}$$

$$= G^{-1} \tilde{\lambda}_{i1}^{-1} \tilde{\lambda}_{i2} \tilde{\lambda}_{i2}^{-1} \tilde{\lambda}_{i1} G^{-1}$$

$$\Rightarrow G^{-1} \alpha \text{ es autovector de } V_{\tilde{X}} \Rightarrow V_{\tilde{X}} G^{-1} \alpha = \lambda^2 G^{-1} \alpha$$

$$\tilde{\lambda}_{i1}^{-1} \tilde{\lambda}_{i2} \tilde{\lambda}_{i2}^{-1} \tilde{\lambda}_{i1} G^{-1} G^{-1} \alpha = \lambda^2 G^{-1} G^{-1} \alpha$$

$$\Rightarrow \underbrace{G^{-1} \tilde{\lambda}_{i1}^{-1}}_{V_X} \underbrace{\tilde{\lambda}_{i2} \tilde{\lambda}_{i2}^{-1}}_{\lambda} \underbrace{\tilde{\lambda}_{i1}}_{\alpha} = \lambda^2 \underbrace{G^{-1} \alpha}_{\alpha}$$

$$\Rightarrow G^{-1} \alpha \text{ es autovector de } V_{\tilde{X}} \text{ Análogamente}$$

$$F^{-1} \beta \text{ " " " " } V_{\tilde{Y}} = F^{-1} \tilde{\lambda}_{i2}^{-1} \tilde{\lambda}_{i1} \tilde{\lambda}_{i1}^{-1} \tilde{\lambda}_{i2} F$$

Notemos que:

$$\mu_{\tilde{X}} = \alpha'_{\tilde{X}} \alpha_{\tilde{X}} = \alpha' G^{-1} G \alpha = \alpha' \alpha$$

$$\text{idem } \mu_{\tilde{Y}}$$

Correlación canónica: En la práctica

Si en lugar de variables aleatorias tenemos datos entonces debemos estimar las matrices de covarianzas.

Es decir estimamos $\hat{\Sigma}_{11}$, $\hat{\Sigma}_{12}$, $\hat{\Sigma}_{22}$ y $\hat{\Sigma}_{21}$ y luego calculamos


- $\hat{\rho}_r^2$ es el r autovalor más grande de $\hat{\Sigma}_{11}^{-1} \hat{\Sigma}_{12} \hat{\Sigma}_{22}^{-1} \hat{\Sigma}_{21}$
- $\hat{\alpha}_r$ es el autovector de $\hat{\Sigma}_{11}^{-1} \hat{\Sigma}_{12} \hat{\Sigma}_{22}^{-1} \hat{\Sigma}_{21}$ asociado a $\hat{\rho}_r^2$ tal que $\hat{\alpha}_r^t \hat{\Sigma}_{11} \hat{\alpha}_r = 1$.
- $\hat{\beta}_r$ es el autovector de $\hat{\Sigma}_{22}^{-1} \hat{\Sigma}_{21} \hat{\Sigma}_{11}^{-1} \hat{\Sigma}_{12}$ asociado a $\hat{\rho}_r^2$ tal que $\hat{\beta}_r^t \hat{\Sigma}_{22} \hat{\beta}_r = 1$.

Correlación canónica: Interpretación geométrica

$\mathbf{X} \in \mathbb{R}^{n \times k}$ e $\mathbf{Y} \in \mathbb{R}^{n \times q}$ de rango p y q respectivamente.

Las p columnas de $\mathbf{X}$ generan un subespacio $P1$ de dimensión p (y lo mismo para $\mathbf{Y}$, $P2$). Proyectamos $\mathbf{Y}$ en $P1$ y $\mathbf{X}$ en $P2$. El ángulo que forman

$$(\cos(\theta))^2 = \frac{(\boldsymbol{\alpha}^t \hat{\boldsymbol{\Sigma}}_{12} \boldsymbol{\beta})^2}{(\boldsymbol{\alpha}^t \hat{\boldsymbol{\Sigma}}_{11} \boldsymbol{\alpha})(\boldsymbol{\beta}^t \hat{\boldsymbol{\Sigma}}_{22} \boldsymbol{\beta})}$$



(del libro Análisis Multivariante de Daniel Peña)

Correlación canónica

Cosas que no vimos, pero están cerca:

- se puede extender a más de dos grupos
- se puede hacer test de hipótesis a las correlaciones
- se puede estudiar

$$E((\mathbf{BY} - \nu - \mathbf{AX})(\mathbf{BY} - \nu - \mathbf{AX})^t)$$

en función de r para elegir el r óptimo

- análisis de redundancia: el CCA es simétrico ¿qué pasa si no queremos que el papel de $\mathbf{X}$ con $\mathbf{Y}$ sea simétrico?
- Correlación canónica funcional.

Ejemplo

Los datos que se analizan corresponden a 51 hogares españoles. Las primeras 5 variables son relativas a gastos del hogar en distintas partidas y las últimas 4 a la estructura del hogar:


Gastos de

- : Y_1 : alimentación, bebidas y tabaco
- : Y_2 : vestimenta y calzado
- : Y_3 : artículos para el hogar
- : Y_4 : transporte y comunicación
- : Y_5 : esparcimiento y enseñanza

Estructura del hogar

- : X_1 : número de personas
- : X_2 : número de personas mayores a 14 años
- : X_3 : nivel educativo del/la jefe/a (1:analfabeto a 8: est.superiores)
- : X_4 : número de asalariados

Ejemplo



Xcor	x1	x2	x3	x4
x1	1.000	0.553	0.115	0.534
x2	0.553	1.000	0.039	-0.107
x3	0.115	0.039	1.000	0.003
x4	0.534	-0.107	0.003	1.000

Ycor	y1	y2	y3	y4	y5
y1	1.000	0.287	0.126	0.234	0.335
y2	0.287	1.000	0.250	0.227	0.323
y3	0.126	0.250	1.000	0.350	0.223
y4	0.234	0.227	0.350	1.000	0.363
y5	0.335	0.323	0.223	0.363	1.000

XYcor	y1	y2	y3	y4	y5
x1	0.461	0.347	0.046	0.327	0.288
x2	0.026	0.183	-0.016	0.134	0.172
x3	0.224	0.316	0.506	0.263	0.228
x4	0.401	0.141	-0.019	0.252	0.166

Vamos a hacer el análisis usando las matrices de correlación.

Los valores propios son:

Número	Valor Propio	Correlacion	Prop.
1	0.43997319	0.6633047	0.61552519
2	0.20924770	0.4574360	0.29273881
3	0.05364298	0.2316095	0.07504686
4	0.01192928	0.1092213	0.01668914

Notemos que el primer valor propio 0.43997319 corresponde al cuadrado de la correlación entre las dos primeras correlaciones canónicas.

En este caso los vectores propios son:

ccXYc\$coef

	[,1]	[,2]	[,3]	[,4]
x1	-0.81030121	-0.5009944	0.34766036	1.4135250
x2	0.28643701	0.1008953	-1.17470678	-0.8252833
x3	-0.58681493	0.7879101	-0.01030527	-0.2458441
x4	-0.07682142	-0.3029516	-0.09282264	-1.4110997

ccXYc\$ycoef

	[,1]	[,2]	[,3]	[,4]
y1	-0.5921157	-0.45905016	0.7573082	0.11955769
y2	-0.3328983	0.05735157	-0.5447371	0.79907693
y3	-0.2412316	0.97138157	0.4074352	-0.08816132
y4	-0.2926785	-0.30015343	-0.2871222	-0.72668395
y5	-0.0319383	0.03257163	-0.5810321	-0.24835375

Esto quiere decir, redondeando y cambiando de signo, que

$$v_1 = 0.59y_1 + 0.33y_2 + 0.24y_3 + 0.29y_4 + 0.03y_5$$

y

$$u_1 = 0.81x_1 - 0.28x_2 + 0.59x_3 + 0.07x_4$$

De la expresión que obtuvimos para u_1 vemos que es un promedio de gastos de la familia dando mayor peso a la alimentación y menos a los gastos de esparcimiento y enseñanza.

Respecto del indicador de estructura, v_1 , pondera principalmente el tamaño de la familia y el nivel de educación.

Las segundas variables canónicas explican aproximadamente un 29 %.

El indicador de las variables de gastos contrapone los gastos en alimentación y transporte a los gastos en artículos del hogar y encuentra que este indicador está especialmente relacionado con un indicador de la diferencia entre el nivel de educación y el tamaño familiar.

Ejemplo

