

Reducción de la dimensión

Análisis de Componentes Principales

Datos de alta dimensión

En la actualidad la dimensión de un conjunto de datos puede incrementarse dramáticamente ya que involucran una gran cantidad de características (*features*):

- Imágenes: miles de píxeles
- Genómica: expresión de miles de genes

Reducción de la dimensión: ¿Para qué?

Queremos reducir la dimensión para:

- evitar características irrelevantes o redundantes
- facilitar la interpretación y la visualización
- hacer tratable el problema computacionalmente
- para evitar la maldición de la dimensión


Reducción de la dimensión

Si tenemos datos en dimensión alta buscamos proyectar esos datos en un espacio de dimensión menor sin perder información importante.


Existe principalmente dos formas de reducir dimensión

- seleccionando variables
- combinando las variables originales

¿Qué coordenadas usamos?



¿Qué coordenadas usamos?




¿Qué coordenadas usamos?



¿Qué coordenadas usamos?



Sacando una foto a una tetera...



Ver: Tetera.mp4

Gracias:

<https://blog.ephorie.de/intuition-for-principal-component-analysis-pca>

Reducción de la dimensión

Si tenemos datos en dimensión alta buscamos proyectar esos datos en un espacio de dimensión menor sin perder información importante.

Existe principalmente dos formas de reducir dimensión

- seleccionando variables
- combinando las variables originales

¿Cómo elegimos las **mejores** variables para usar?

Queremos realizar esta reducción conservando algún tipo de propiedad de optimalidad.

Reducción de la dimensión: Combinando variables

Las primeras técnicas fueron métodos lineales.

- Análisis de componentes principales (PCA), (Hotelling 1933).
- Análisis de correlación canónica (CCA), (Hotelling 1936).

Estas dos técnicas tienen una interesante visualización y se resuelven como problemas de autovalores y autovectores.

También se las puede traducir a problemas de regresión lineal, pero esto es a posteriori.

Componentes Principales

Vamos a ver dos enfoques para introducirlas, pero al fin de cuentas es lo mismo.

Primer Enfoque: buscamos combinaciones lineales de las variables que

- sean no correlacionadas
- den la mejor aproximación de baja dimensión a los datos.

La primera componente principal es la combinación lineal con varianza máxima; básicamente, buscamos una dimensión a lo largo de la cual las observaciones estén separadas o dispersas al máximo. La segunda componente principal es la combinación lineal con varianza máxima en una dirección ortogonal a la primera componente principal, y así sucesivamente.

Vamos a empezar suponiendo que tenemos:

una muestra $\mathbf{X}_1, \dots, \mathbf{X}_n \in \mathbb{R}^p$ centrada, es decir $\sum_{i=1}^n \mathbf{X}_i = \mathbf{0}$.

Búsqueda de la Primera Componente

- Muestra centrada $\mathbf{X}_1, \dots, \mathbf{X}_n$
- 1ra. CP: Buscamos $\mathbf{a}$, con $\|\mathbf{a}\| = 1$, tal que si definimos $Y_i = \mathbf{X}_i^t \mathbf{a}$ (matricialmente $\mathbf{Y} = \mathbf{X}\mathbf{a}$), maximice la varianza muestral de $Y_1, \dots, Y_n$

$$\frac{1}{n} \sum_{i=1}^n (\mathbf{a}^t \mathbf{X}_i)^2$$

Veremos usando el lema que la solución es $\mathbf{a} = \hat{\gamma}_1$ autovector de

$$\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \mathbf{X}_i^t$$

asociado a $\hat{\lambda}_1$, el autovalor más grande de $\hat{\Sigma}$ ($\hat{\lambda}_1 \geq \hat{\lambda}_2 \geq \dots \geq \hat{\lambda}_p$).

Por lo tanto, la primera componente resulta $\mathbf{X}\hat{\gamma}_1$ y su varianza es $\hat{\lambda}_1$.

Búsqueda de la Segunda Componente

- 2da. CP: Buscamos $\mathbf{a}$, con $\|\mathbf{a}\| = 1$, tal que si $W_i = \mathbf{X}_i^t \mathbf{a}$ con covarianza muestral nula

$$\sum_{i=1}^n Y_i W_i = \mathbf{Y}^t \mathbf{W} = 0,$$

siendo $Y_i = \mathbf{a}_1^t \mathbf{X}_i$, maximice la varianza muestral de $W_1, \dots, W_n$

$$\frac{1}{n} \sum_{i=1}^n (\mathbf{a}^t \mathbf{X}_i)^2 = \frac{1}{n} \sum_{i=1}^n W_i^2.$$

Nuevamente, usando el lema tenemos que la solución es $\hat{\gamma}_2$ que es el autovector asociado a $\hat{\lambda}_2$, el **segundo autovalor más grande** de la matriz $\hat{\Sigma}$.

- Y así sucesivamente.

Reducción de la dimensión

Segundo Enfoque: Buscamos el subespacio $\mathcal{V}$ de dimensión k que mejor aproxime a los datos.

¿En qué sentido mejor?

Dado un subespacio $\mathcal{V}$ de dimensión k llamamos $P_{\mathcal{V}}(\mathbf{x})$ a la proyección ortogonal del vector $\mathbf{x}$ sobre $\mathcal{V}$.

Luego, encontrar el mejor subespacio de dimensión k es en el sentido

$$\min_{\mathcal{V}} \frac{1}{n} \sum_{i=1}^n \|\mathbf{X}_i - P_{\mathcal{V}}(\mathbf{X}_i)\|^2$$

Censo Socio-económico


El conjunto de datos que consideramos corresponden a un censo distrital sobre cinco variables socioeconómicas para el área de Madison, Wisconsin.

En 61 distritos se miden las variables:


- población total (miles)
- grado profesional (%)
- empleados edad mayor de 16 (%)
- empleados gubernamentales (%)
- mediana valor de la vivienda (U 100000)

Vamos a empezar usando sólo 2 variables: grado profesional (%) y empleados gubernamentales para facilitar la visualización


Diagramas de dispersión




Diagramas de dispersión: Empleados Gob vs. Grado Prof.



Proyecciones sobre $\mathbf{a} = (1, 0.2)^t$



Proyecciones sobre el ortogonal de a



Por Pitágoras tenemos

$$\begin{aligned} \min_{\mathcal{V}} \frac{1}{n} \sum_{i=1}^n \|\mathbf{X}_i - P_{\mathcal{V}}(\mathbf{X}_i)\|^2 &= \\ \min_{\mathcal{V}} \frac{1}{n} \sum_{i=1}^n \left[\|\mathbf{X}_i\|^2 - \|P_{\mathcal{V}}(\mathbf{X}_i)\|^2 \right] \end{aligned}$$

Entonces, tenemos que encontrar

$$\max_{\mathcal{V}} \frac{1}{n} \sum_{i=1}^n \|P_{\mathcal{V}}(\mathbf{X}_i)\|^2$$

Caso $k = 1$

En este caso $\mathcal{V}$ es un subespacio generado por un vector $\mathbf{a}$: $\mathcal{V} = \langle \mathbf{a} \rangle$, $\mathbf{a} \in \mathbb{R}^p$ con $\|\mathbf{a}\| = 1$. Luego,

$$P_{\mathcal{V}}(\mathbf{X}_i) = \mathbf{a} (\mathbf{a}^t \mathbf{X}_i)$$


entonces

$$\sum_{i=1}^n \|P_{\mathcal{V}}(\mathbf{X}_i)\|^2 = \sum_{i=1}^n \|\mathbf{a} (\mathbf{a}^t \mathbf{X}_i)\|^2$$


Por lo tanto:

$$\begin{aligned} \max_{\mathcal{V}} \frac{1}{n} \sum_{i=1}^n \|P_{\mathcal{V}}(\mathbf{X}_i)\|^2 &= \max_{\|\mathbf{a}\|=1} \frac{1}{n} \sum_{i=1}^n \|\mathbf{a} (\mathbf{a}^t \mathbf{X}_i)\|^2 = \\ \max_{\|\mathbf{a}\|=1} \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i^t \mathbf{a} \mathbf{a}^t \mathbf{a} \mathbf{a}^t \mathbf{X}_i &= \max_{\|\mathbf{a}\|=1} \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i^t \mathbf{a} \mathbf{a}^t \mathbf{X}_i \\ \max_{\|\mathbf{a}\|=1} \frac{1}{n} \sum_{i=1}^n \mathbf{a}^t \mathbf{X}_i \mathbf{X}_i^t \mathbf{a} &= \max_{\|\mathbf{a}\|=1} \mathbf{a}^t \left[\frac{1}{n} \sum_{i=1}^n \mathbf{X}_i \mathbf{X}_i^t \right] \mathbf{a} \\ &= \max_{\|\mathbf{a}\|=1} \mathbf{a}^t \hat{\Sigma} \mathbf{a} \end{aligned}$$

PC1 y PC2



PC1 y proyecciones



Componentes Principales

En resumen:

- el "mejor" subespacio $\mathcal{V}$ de dimensión **1** es generado por el autovector $\hat{\gamma}_1$ of $\hat{\Sigma}$ asociado con el autovector más grande $\hat{\lambda}_1$.
- Llamamos **scores** a los coeficientes de las proyecciones

$$Y_i = \hat{\gamma}_1^t \mathbf{X}_i, \quad i = 1, \dots, n$$

- Las proyecciones son

$$\mathbf{v}_i = \hat{\gamma}_1 Y_i = \hat{\gamma}_1 (\hat{\gamma}_1^t \mathbf{X}_i), \quad i = 1, \dots, n$$

Caso $k > 1$

Veamos el caso general. Sea $\mathbf{T} \in \mathbb{R}^{p \times k}$ una matriz ortonormal ($\mathbf{T}^t \mathbf{T} = \mathbf{I}_k$) base de $\mathcal{V}$, entonces

$$P_{\mathcal{V}}(\mathbf{X}_i) = \mathbf{T} (\mathbf{T}^t \mathbf{X}_i)$$

Luego,

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n \|P_{\mathcal{V}}(\mathbf{X}_i)\|^2 &= \frac{1}{n} \sum_{i=1}^n \|\mathbf{T} (\mathbf{T}^t \mathbf{X}_i)\|^2 \\ &= \frac{1}{n} \sum_{i=1}^n \underbrace{\mathbf{X}_i^t \mathbf{T} \mathbf{T}^t \mathbf{X}_i}_{\in \mathbb{R}} = \frac{1}{n} \sum_{i=1}^n \text{tr}(\underbrace{\mathbf{X}_i^t \mathbf{T}}_{\in \mathbb{R}} \underbrace{\mathbf{T}^t \mathbf{X}_i}_{\in \mathbb{R}}) \\ &\stackrel{\text{tr}(\mathbf{AB})=\text{tr}(\mathbf{BA})}{=} \frac{1}{n} \sum_{i=1}^n \text{tr}(\mathbf{T}^t \mathbf{X}_i \mathbf{X}_i^t \mathbf{T}) \\ &= \text{tr}(\mathbf{T}^t \hat{\Sigma} \mathbf{T}) \leq \sum_{j=1}^k \hat{\lambda}_j \end{aligned}$$

donde en la última desigualdad aplicamos el [Lema de Separación de Poincaré](#).

Caso $k > 1$

Entonces, si $\mathbf{T} = \mathbf{U}_k$, matriz con los *primeros* autovectores, resulta que

$$\text{traza}(\mathbf{U}_k^t \hat{\Sigma} \mathbf{U}_k) = \sum_{j=1}^k \hat{\lambda}_j$$

entonces el mejor subespacio es el generado por los *primeros* autovectores de $\hat{\Sigma}$.

Usando SDV

Consideremos una vez más la matriz de datos centrados $\mathbf{X} \in \mathbb{R}^{n \times p}$.

Por lo que recordamos sobre la descomposición en valores singulares (SDV), podemos escribirla como

$$\mathbf{X} = \hat{\mathbf{U}} \hat{\mathbf{\Lambda}} \hat{\mathbf{V}}^t$$

donde la matriz $n \times p$ es tal que $\hat{\mathbf{\Lambda}}_{ii}$ es $\hat{\sigma}_i \geq 0$ para $i = 1, 2, \dots, p$ (asumimos $p \leq n$) y las otras posiciones son nulas, siendo $\hat{\sigma}_i$ los valores singulares de $\mathbf{X}$.

Notemos que

$$\begin{aligned}\mathbf{X}^t \mathbf{X} &= \widehat{\mathbf{V}} \widehat{\mathbf{\Lambda}}^t \widehat{\mathbf{U}}^t \widehat{\mathbf{U}} \widehat{\mathbf{\Lambda}} \widehat{\mathbf{V}}^t = \widehat{\mathbf{V}} \widehat{\mathbf{\Lambda}}^t \widehat{\mathbf{\Lambda}} \widehat{\mathbf{V}}^t = \\ &= \widehat{\mathbf{V}} \begin{bmatrix} \widehat{\sigma}_1^2 & \dots & 0 \\ 0 & \widehat{\sigma}_2^2 & 0 \\ \dots & \dots & \dots \\ 0 & & \widehat{\sigma}_p^2 \end{bmatrix} \widehat{\mathbf{V}}^t\end{aligned}$$

y

$$\begin{aligned}\mathbf{X} \mathbf{X}^t &= \widehat{\mathbf{U}} \widehat{\mathbf{\Lambda}} \widehat{\mathbf{V}}^t \widehat{\mathbf{V}} \widehat{\mathbf{\Lambda}}^t \widehat{\mathbf{U}}^t = \widehat{\mathbf{U}} \widehat{\mathbf{\Lambda}} \widehat{\mathbf{\Lambda}}^t \widehat{\mathbf{U}}^t = \\ &= \widehat{\mathbf{U}}^t \begin{bmatrix} \widehat{\sigma}_1^2 & 0 & 0 & 0 & \dots & 0 \\ 0 & \widehat{\sigma}_2^2 & 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & \widehat{\sigma}_p^2 & 0 & \dots & 0 \\ 0 & 0 & 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots & \dots & \dots \\ 0 & 0 & 0 & 0 & \dots & 0 \end{bmatrix} \widehat{\mathbf{U}}\end{aligned}$$

Ejemplo

Analicemos ahora las 5 variables del problema del censo.

Vamos a R

Ejemplo

Analicemos el ejemplo de los dígitos.

Vamos a R

PCA: cantidad de componentes

Una cosa importante :

- ¿Cuántas componentes usamos?
- Cuantas menos componentes usamos, mayor es la reducción que logramos
- Cuantas más componentes usamos, mayor es la aproximación a los datos que logramos
- Existe un trade-off entre estas dos cosas

¿Con qué criterio elegimos k ?

PCA: cantidad de componentes

Notemos que para cada dimensión k la pérdida (loss) es:

$$\begin{aligned}\mathcal{L}(k) &= \min_{\mathcal{V}} \frac{1}{n} \sum_{i=1}^n \|\mathbf{X}_i - P_{\mathcal{V}}(\mathbf{X}_i)\|^2 &= \min_{\mathcal{V}} \frac{1}{n} \sum_{i=1}^n \left[\|\mathbf{X}_i\|^2 - \|P_{\mathcal{V}}(\mathbf{X}_i)\|^2 \right] \\ \frac{1}{n} \sum_{i=1}^n \|\mathbf{X}_i\|^2 - \max_{\mathcal{V}} \frac{1}{n} \sum_{i=1}^n \|P_{\mathcal{V}}(\mathbf{X}_i)\|^2 &= \text{tr}(\widehat{\Sigma}) - \sum_{j=1}^k \widehat{\lambda}_j \\ &= \sum_{j=k+1}^p \widehat{\lambda}_j\end{aligned}$$

PCA: cantidad de componentes

Notemos que para cada dimensión k la pérdida (loss) es:

$$\begin{aligned}\mathcal{L}(k) &= \min_{\mathcal{V}} \frac{1}{n} \sum_{i=1}^n \|\mathbf{X}_i - P_{\mathcal{V}}(\mathbf{X}_i)\|^2 = \min_{\mathcal{V}} \frac{1}{n} \sum_{i=1}^n \left[\|\mathbf{X}_i\|^2 - \|P_{\mathcal{V}}(\mathbf{X}_i)\|^2 \right] \\ \frac{1}{n} \sum_{i=1}^n \|\mathbf{X}_i\|^2 - \max_{\mathcal{V}} \frac{1}{n} \sum_{i=1}^n \|P_{\mathcal{V}}(\mathbf{X}_i)\|^2 &= \text{tr}(\hat{\Sigma}) - \sum_{j=1}^k \hat{\lambda}_j \\ &= \sum_{j=k+1}^p \hat{\lambda}_j\end{aligned}$$

Observemos que al pasar de k a $k+1$ componentes, la diferencia entre las pérdidas es:

$$\mathcal{L}(k) - \mathcal{L}(k+1) = \hat{\lambda}_{k+1}$$

y como los autovalores cumplen $\hat{\lambda}_1 \geq \hat{\lambda}_2 \cdots \geq \hat{\lambda}_p$, la ganancia es decreciente.

En el *scree plot* (Cattell, 1966) se representa el orden del autovalor vs. autovalor. cantidad de componentes

PCA: cantidad de componentes

Por las propiedades vistas:

$$\text{variabilidad total} = \text{tr}(\widehat{\Sigma}) = \sum_{j=1}^p \widehat{\lambda}_j$$

Luego, las primeras k componentes explican de la variabilidad total la siguiente proporción:

$$\frac{\sum_{j=1}^k \widehat{\lambda}_j}{\sum_{j=1}^p \widehat{\lambda}_j}$$

En este sentido, hay distintos criterios para elegir k :

- Nos quedamos con las k primeras componentes que explican un determinado porcentaje de la variabilidad total (por ejemplo, 80 %)
- A partir del Scree plot se busca un efecto de codo, es decir se busca el k para el cual la componente principal aporta algo similar a la siguiente.

Ejemplo

Vayamos a los ejemplos.

¿Y la Estadística que aporta a esto?

Pensamos a los vectores $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ como copias independientes de un vector aleatorio $\mathbf{X} = (X_1, X_2, \dots, X_p)^t$.

De acuerdo a lo visto:

buscamos un conjunto de proyecciones lineales ortogonales de $\mathbf{X}$

donde las proyecciones estén ordenadas de forma decreciente según su varianza teniendo en cuenta que

- la varianza que es una medida que cuantifica la cantidad de información. A través de la varianza medimos optimalidad.

¿Y la Estadística que aporta a esto?

Pensamos a los vectores $\mathbf{X}_1, \mathbf{X}_2, \dots, \mathbf{X}_n$ como copias independientes de un vector aleatorio $\mathbf{X} = (X_1, X_2, \dots, X_p)^t$.

De acuerdo a lo visto:

buscamos un conjunto de proyecciones lineales ortogonales de $\mathbf{X}$

donde las proyecciones estén ordenadas de forma decreciente según su varianza teniendo en cuenta que

- la varianza que es una medida que cuantifica la cantidad de información. A través de la varianza medimos optimalidad.
- el resultado provoca una rotación o cambio del sistema de coordenadas de modo que las proyecciones no estén correlacionadas.

Desde la Estadística

Sea $\mathbf{X} = (X_1, X_2, \dots, X_p)^t$ tal que

$$\mathbb{E}(\mathbf{X}) = \mathbf{0} \qquad \Sigma_{\mathbf{X}\mathbf{X}} = \Sigma$$

.

Buscamos reemplazar las p variables (sin orden y correlacionadas) por un conjunto de k nuevas variables no correlacionadas que sean una combinación lineal de las variables originales.

Queremos elegir $k \leq p$ combinaciones lineales

$$\xi_1 = \mathbf{b}_1^t \mathbf{X}, \quad \xi_2 = \mathbf{b}_2^t \mathbf{X}, \quad \dots \quad \xi_k = \mathbf{b}_k^t \mathbf{X}$$

de manera de minimizar la pérdida de información que guardan $(X_1, X_2, \dots, X_p)$ debida al reemplazo.

Como vimos, en PCA la información se interpreta en términos de la dispersión total medida a través de $\text{tr}(\Sigma) = \sum_{i=1}^p \text{VAR}(X_i)$.

Recordemos que como Σ es una matriz simétrica, $\Sigma = \Gamma \Lambda \Gamma^t$ donde

$$\Gamma = [\gamma_1 \dots \gamma_p],$$

$\Gamma^t \Gamma = \mathbf{I}_{p \times p}$ y $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_p)$, con $\lambda_1 \geq \lambda_2, \dots \geq \lambda_p$.

Entonces

$$\text{tr}(\Sigma) = \sum_{i=1}^p \text{VAR}(X_i) = \sum_{i=1}^p \lambda_j.$$

Observemos que además como cada coordenada tiene esperanza nula:

$$\text{tr}(\Sigma) = \sum_{i=1}^p \text{VAR}(X_i) = \sum_{i=1}^p \mathbb{E}(X_i^2) = \mathbb{E}\|\mathbf{X}\|^2.$$

Los vectores $\mathbf{b}_1, \dots, \mathbf{b}_k$ se eligen de modo tal que:

- las primeras k proyecciones estén ordenadas de acuerdo a su varianza. $\text{VAR}(\xi_1) \geq \text{VAR}(\xi_2) \geq \dots \geq \text{VAR}(\xi_k)$
- ξ_j no esté correlacionada con ξ_ℓ si $\ell < j$

$\xi_1, \dots, \xi_k$ se las conoce como las primeras k componentes principales.

Dos enfoques

$\xi_1, \dots, \xi_k$ se las conoce como las primeras k componentes principales poblacionales.

Hay dos métodos para obtener quienes son los $\mathbf{b}'_s$ que conducen a lo mismo:

- Maximizando varianza
- Criterio de optimalidad de mínimos cuadrados

1 PCA: como técnica de maximización de varianza

(Hotelling 1933, enfoque original)

Buscamos $\mathbf{b}_1, \dots, \mathbf{b}_k$ tal que

$$\text{VAR}(\xi_1) \geq \text{VAR}(\xi_2) \geq \dots \geq \text{VAR}(\xi_k)$$

para $\text{VAR}(\xi_j) = \text{VAR}(\mathbf{b}_j^t \mathbf{X})$ y $\text{COV}(\xi_j, \xi_\ell) = \text{COV}(\mathbf{b}_j^t \mathbf{X}, \mathbf{b}_\ell^t \mathbf{X}) = 0$ si $j \neq \ell$.

Si $j = 1$, $\mathbf{b}_1$ debe ser tal que $\text{VAR}(\xi_1)$ sea máxima.

$$\text{VAR}(\xi_1) = \text{VAR}(\mathbf{b}_1^t \mathbf{X}) = \mathbf{b}_1^t \boldsymbol{\Sigma} \mathbf{b}_1$$

pero además $\|\mathbf{b}_1\| = 1$.

Esto conduce a un problema de maximización con restricciones: Lema 4?? Lagrange???

1 PCA: como técnica de maximización de varianza

(Hotelling 1933, enfoque original)

Buscamos $\mathbf{b}_1, \dots, \mathbf{b}_k$ tal que

$$\text{VAR}(\xi_1) \geq \text{VAR}(\xi_2) \geq \dots \geq \text{VAR}(\xi_k)$$

para $\text{VAR}(\xi_j) = \text{VAR}(\mathbf{b}_j^t \mathbf{X})$ y $\text{COV}(\xi_j, \xi_\ell) = \text{COV}(\mathbf{b}_j^t \mathbf{X}, \mathbf{b}_\ell^t \mathbf{X}) = 0$ si $j \neq \ell$.

Si $j = 1$, $\mathbf{b}_1$ debe ser tal que $\text{VAR}(\xi_1)$ sea máxima.

$$\text{VAR}(\xi_1) = \text{VAR}(\mathbf{b}_1^t \mathbf{X}) = \mathbf{b}_1^t \Sigma \mathbf{b}_1$$

pero además $\|\mathbf{b}_1\| = 1$.

Esto conduce a un problema de maximización con restricciones: Lema 4?? Lagrange???

Solución: corresponde al autovector relacionado al máximo autovalor de Σ (siendo λ_1 el mayor autovalor de Σ).

1 PCA: como técnica de maximización de varianza

¿Cómo elegimos $\mathbf{b}_2$?

$\text{VAR}(\xi_2) = \text{VAR}(\mathbf{b}_2^t \mathbf{X}) = \mathbf{b}_2^t \Sigma \mathbf{b}_2$ debe ser máxima, $\|\mathbf{b}_2\| = 1$ y $\text{COV}(\xi_1, \xi_2) = \text{COV}(\mathbf{b}_1^t \mathbf{X}, \mathbf{b}_2^t \mathbf{X}) = 0$.

Es decir, maximizar $\mathbf{b}_2^t \Sigma \mathbf{b}_2$

sujeto a $\mathbf{b}_2^t \mathbf{b}_2 = 1$ y $\mathbf{b}_2^t \Sigma \mathbf{b}_1 = 0$ ($\mathbf{b}_1^t \mathbf{b}_2 = 0$).

Esto conduce a otro problema de maximización con restricciones.

Solución: corresponde al autovector relacionado al segundo autovalor mas grande Σ (siendo λ_2 el segundo autovalor ordenado de Σ).

1 PCA: como técnica de maximización de varianza

¿Cómo elegimos $\mathbf{b}_j$?

Del mismo modo: maximizar $\mathbf{b}_j^t \Sigma \mathbf{b}_j$

sujeto a $\mathbf{b}_j^t \mathbf{b}_j = 1$ y $\mathbf{b}_j^t \Sigma \mathbf{b}_i = 0$ si $i < j$

1 PCA: como técnica de maximización de varianza

¿Cómo elegimos $\mathbf{b}_j$?

Del mismo modo: maximizar $\mathbf{b}_j^t \Sigma \mathbf{b}_j$

sujeto a $\mathbf{b}_j^t \mathbf{b}_j = 1$ y $\mathbf{b}_j^t \Sigma \mathbf{b}_i = 0$ si $i < j$

Solución: $\mathbf{b}_j$ es el autovector correspondiente al j -ésimo autovalor más grande de Σ

2 PCA: como un problema de mínimos cuadrados

Podemos escribir las proyecciones en términos de una matriz.

Sea $\mathbf{B} = (\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_k)^t$, es decir $\mathbf{B} \in \mathbb{R}^{p \times k}$ entonces

$$\boldsymbol{\xi} = \mathbf{B}\mathbf{X} = \begin{pmatrix} \mathbf{b}_1^t \\ \cdot \\ \cdot \\ \mathbf{b}_k^t \end{pmatrix} \mathbf{X} = \begin{pmatrix} \xi_1 \\ \cdot \\ \cdot \\ \xi_k \end{pmatrix}$$

$$\xi_1 = \mathbf{b}_1^t \mathbf{X}, \quad \xi_2 = \mathbf{b}_2^t \mathbf{X}, \quad \dots \quad \xi_k = \mathbf{b}_k^t \mathbf{X}$$

Buscamos un vector $\boldsymbol{\mu}$ y una matriz $\mathbf{A}$ de rango completo tal que $\boldsymbol{\mu} + \mathbf{A}\boldsymbol{\xi}$ aproxime a $\mathbf{X}$.

2 PCA: como un problema de mínimos cuadrados

Podemos escribir las proyecciones en términos de una matriz.

Sea $\mathbf{B} = (\mathbf{b}_1, \mathbf{b}_2, \dots, \mathbf{b}_k)^t$, es decir $\mathbf{B} \in \mathbb{R}^{p \times k}$ entonces

$$\boldsymbol{\xi} = \mathbf{B}\mathbf{X} = \begin{pmatrix} \mathbf{b}_1^t \\ \cdot \\ \cdot \\ \mathbf{b}_k^t \end{pmatrix} \mathbf{X} = \begin{pmatrix} \xi_1 \\ \cdot \\ \cdot \\ \xi_k \end{pmatrix}$$

$$\xi_1 = \mathbf{b}_1^t \mathbf{X}, \quad \xi_2 = \mathbf{b}_2^t \mathbf{X}, \quad \dots \quad \xi_k = \mathbf{b}_k^t \mathbf{X}$$

Buscamos un vector $\boldsymbol{\mu}$ y una matriz $\mathbf{A}$ de rango completo tal que $\boldsymbol{\mu} + \mathbf{A}\boldsymbol{\xi}$ aproxime a $\mathbf{X}$.

¿En qué sentido? En el sentido de cuadrados mínimos:

$$E((\mathbf{X} - \boldsymbol{\mu} - \mathbf{A}\boldsymbol{\xi})(\mathbf{X} - \boldsymbol{\mu} - \mathbf{A}\boldsymbol{\xi})^t)$$

sea mínimo

2 PCA: como un problema de mínimos cuadrados

El problema se traduce en encontrar μ , $\mathbf{A}$ y $\mathbf{B}$ que minimicen

$$E((\mathbf{X} - \mu - \mathbf{A}\mathbf{B}\mathbf{X})(\mathbf{X} - \mu - \mathbf{A}\mathbf{B}\mathbf{X})^t)$$

$\mathbf{A}$ y $\mathbf{B}$ deben ser de rango completo.

Se puede ver que $\mathbf{A} = \mathbf{B}^t = [\gamma_1 \dots \gamma_k]$ con γ_i los autovectores de Σ ordenados según los autovectores como antes.

Además resulta que

$$E((\mathbf{X} - \mu_{opt} - \mathbf{A}_{opt}\mathbf{B}_{opt}\mathbf{X})(\mathbf{X} - \mu_{opt} - \mathbf{A}_{opt}\mathbf{B}_{opt}\mathbf{X})^t) = \sum_{i=k+1}^p \lambda_j$$

Es decir la suma de los autovalores más pequeños.

Componentes Principales: Muestrales

En la práctica no tenemos una variable aleatoria sino una muestra aleatoria y no tenemos Σ .

Lo que hicimos inicialmente fue trabajar con las versiones muestrales

Componentes Principales: Muestrales

En la práctica no tenemos una variable aleatoria sino una muestra aleatoria y no tenemos Σ .

Lo que hicimos inicialmente fue trabajar con las versiones muestrales

Dados $\mathbf{X}_1, \dots, \mathbf{X}_n$ independientes, $\mathbf{X}_i \in \mathbb{R}^p$, $\mathbb{E}(\mathbf{X}_i) = \boldsymbol{\mu}$,
 $\text{COV}(\mathbf{x}_i) = \Sigma$

$$\begin{aligned}\hat{\boldsymbol{\mu}} &= \overline{\mathbf{X}} \\ \hat{\Sigma} &= \frac{1}{n} \sum_{i=1}^n (\mathbf{X}_i - \overline{\mathbf{X}})(\mathbf{X}_i - \overline{\mathbf{X}})^t = \frac{\mathbf{Q}}{n}\end{aligned}$$

Componentes principales muestrales: $\hat{\Sigma} = \hat{\Gamma} \hat{\Delta} \hat{\Gamma}^t$

$$\hat{\mu} = \overline{\mathbf{X}}$$

$$\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n (\mathbf{X}_i - \overline{\mathbf{X}})(\mathbf{X}_i - \overline{\mathbf{X}})^t = \frac{\mathbf{Q}}{n}$$

- $\hat{\lambda}_1 > \dots > \hat{\lambda}_p$ los autovalores de $\hat{\Sigma}$ y
- $\hat{\gamma}_1, \dots, \hat{\gamma}_p$ los autovectores de $\hat{\Sigma}$ asociados a $\hat{\lambda}_1 > \dots > \hat{\lambda}_p$.

Caso Normal

Sea $\mathbf{X} \in \mathbb{R}^p$ tal que

$$\mathbb{E}(\mathbf{X}) = \boldsymbol{\mu} \qquad \text{VAR}(\mathbf{X}) = \boldsymbol{\Sigma}$$

Sean

- $\lambda_1 \geq \dots \geq \lambda_p$ los autovalores de $\boldsymbol{\Sigma}$
- $\boldsymbol{\gamma}_1, \dots, \boldsymbol{\gamma}_p$ los autovectores de $\boldsymbol{\Sigma}$ asociados a $\lambda_1 \geq \dots \geq \lambda_p$
- $\boldsymbol{\Gamma} = [\boldsymbol{\gamma}_1 \dots \boldsymbol{\gamma}_p]$, $\boldsymbol{\Gamma}^t \boldsymbol{\Gamma} = \mathbf{I}_p$
- $\boldsymbol{\Delta} = \text{diag}(\lambda_1, \dots, \lambda_p)$

$$\boldsymbol{\Gamma}^t \boldsymbol{\Sigma} \boldsymbol{\Gamma} = \boldsymbol{\Delta}, \qquad \boldsymbol{\Sigma} = \sum_{j=1}^p \lambda_j \boldsymbol{\gamma}_j \boldsymbol{\gamma}_j^t = \boldsymbol{\Gamma} \boldsymbol{\Delta} \boldsymbol{\Gamma}^t$$

Inferencia en el caso normal

Sean $\mathbf{X}_1, \dots, \mathbf{X}_n$ i.i.d $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\boldsymbol{\Sigma} = \boldsymbol{\Gamma} \boldsymbol{\Delta} \boldsymbol{\Gamma}^t$, con $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p$, entonces

$\hat{\boldsymbol{\mu}} = \bar{\mathbf{X}}$ y $\hat{\boldsymbol{\Sigma}} = \frac{1}{n} \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})^t$ son los estimadores de máxima verosimilitud de $\boldsymbol{\mu}$ y $\boldsymbol{\Sigma}$, respectivamente.

Inferencia en el caso normal




FIGURE 7.3. Scree plots of the ordered eigenvalues of $\hat{\Sigma}_{XX} = n^{-1}\mathcal{X}\mathcal{X}^\tau$, where $\mathcal{X} = \mathbf{D}\mathcal{Z}$, $\mathbf{D}$ is a diagonal $(r \times r)$ -matrix, and the elements of the $(r \times n)$ -matrix $\mathcal{Z}$ are each independent Gaussian deviates. In this simulation, $r = 30$ and $\mathbf{D}^2 = \text{Diag}(12, 11, 10, 9, 8, 7, 3, 3, 3, \dots, 3)$. The left panel corresponds to $n = 300$ and has an elbow at 7, and the right panel corresponds to $n = 30$ and shows no elbow.

Inferencia en el caso normal

Teorema. Sean $\mathbf{X}_1, \dots, \mathbf{X}_n$ i.i.d $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\boldsymbol{\Sigma} = \boldsymbol{\Gamma} \boldsymbol{\Delta} \boldsymbol{\Gamma}^t$, con $\lambda_1 > \lambda_2 > \dots > \lambda_p > 0$, entonces

- $\hat{\boldsymbol{\Delta}} = \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_p)$ es el EMV de $\boldsymbol{\Delta}$
- $\hat{\boldsymbol{\Gamma}} = (\hat{\gamma}_1, \dots, \hat{\gamma}_p)$ es el EMV de $\boldsymbol{\Gamma}$

Inferencia en el caso normal

Teorema. Sean $\mathbf{X}_1, \dots, \mathbf{X}_n$ i.i.d $N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, $\boldsymbol{\Sigma} = \boldsymbol{\Gamma} \boldsymbol{\Delta} \boldsymbol{\Gamma}^t$, con $\lambda_1 > \lambda_2 > \dots > \lambda_p > 0$, entonces

- $\hat{\boldsymbol{\Delta}} = \text{diag}(\hat{\lambda}_1, \dots, \hat{\lambda}_p)$ es el EMV de $\boldsymbol{\Delta}$
- $\hat{\boldsymbol{\Gamma}} = (\hat{\gamma}_1, \dots, \hat{\gamma}_p)$ es el EMV de $\boldsymbol{\Gamma}$

Además,

$$\sqrt{n}(\hat{\lambda}_j - \lambda_j) \xrightarrow{D} N(0, 2\lambda_j^2)$$

asintóticamente independientes entre sí.

Si las observaciones no son normales se puede probar que $\hat{\lambda}_j$ es asintóticamente normal con varianza $c\lambda_j^2$ pero no son necesariamente independientes

Más aún

Anderson (1963) y Girshick (1939)

Sean $\hat{\boldsymbol{\lambda}}^t = (\hat{\lambda}_1, \dots, \hat{\lambda}_p)$ y los autovectores asociados $\hat{\gamma}_1, \dots, \hat{\gamma}_p$ of $\hat{\boldsymbol{\Sigma}}$:

1. Si $\boldsymbol{\Delta}$ es $\text{DIAG}(\lambda_1, \dots, \lambda_p)$, luego $\sqrt{n}(\hat{\boldsymbol{\lambda}} - \boldsymbol{\lambda}) \xrightarrow{D} N_p(\mathbf{0}, 2\boldsymbol{\Delta}^2)$.

2. Si

$$\mathbf{E}_i = \lambda_i \sum_{\substack{k=1 \\ k \neq i}}^p \frac{\lambda_k}{(\lambda_k - \lambda_i)^2} \boldsymbol{\gamma}_k \boldsymbol{\gamma}_k^t$$

luego $\sqrt{n}(\hat{\gamma}_i - \gamma_i) \xrightarrow{D} N_p(\mathbf{0}, \mathbf{E}_i)$.

3. Cada $\hat{\lambda}_i$ se distribuye independientemente de las componentes de $\hat{\gamma}_i$.

Intervalo de Confianza

De acuerdo con el punto 1, tenemos que para n suficientemente grande, $\hat{\lambda}_i$ están independientemente distribuidos.

Más aún, para n suficientemente grande, $\hat{\lambda}_i$ se distribuye aproximadamente como $N(\lambda_i, 2\lambda_i^2/n)$

Usando esto, tenemos:

$$P \left[\left| \hat{\lambda}_i - \lambda_i \right| \leq z_{\alpha/2} \lambda_i \sqrt{2/n} \right] \approx 1 - \alpha$$

y obtenemos un intervalo de nivel aproximado $100(1 - \alpha)\%$ para λ_i dado por

$$\frac{\hat{\lambda}_i}{(1 + z_{\alpha/2} \sqrt{2/n})} \leq \lambda_i \leq \frac{\hat{\lambda}_i}{(1 - z_{\alpha/2} \sqrt{2/n})}$$

Si queremos hacer intervalos de confianza para m λ_i el método de Bonferroni provee intervalos de un nivel simultáneo $1 - \alpha$ reemplazando en cada uno $z_{\alpha/2}$ por $z_{\alpha/2m}$.

Test para porcentajes

Queremos testear

$$H_{0,p_0} : \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} = p_0 \quad \text{versus} \quad H_{1,p_0} : \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} \neq p_0$$

donde p_0 es un porcentaje prefijado.

Test para porcentajes

Queremos testear

$$H_{0,p_0} : \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} = p_0 \quad \text{versus} \quad H_{1,p_0} : \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} \neq p_0$$

donde p_0 es un porcentaje prefijado. También podría interesarnos

$$H_{0,p_0}^* : \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} \leq p_0 \quad \text{versus} \quad H_{1,p_0}^* : \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} > p_0$$

Test para porcentajes

Queremos testear

$$H_{0,p_0} : \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} = p_0 \quad \text{versus} \quad H_{1,p_0} : \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} \neq p_0$$

donde p_0 es un porcentaje prefijado. También podría interesarnos

$$H_{0,p_0}^* : \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} \leq p_0 \quad \text{versus} \quad H_{1,p_0}^* : \frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} > p_0$$

Para obtener un test para estas hipótesis nos basaremos en la distribución asintótica de los autovalores

$$\sqrt{n}(\hat{\lambda}_j - \lambda_j) \xrightarrow{D} N(0, 2\lambda_j^2)$$

y usaremos que son asintóticamente independientes entre sí.

Test para porcentajes

Observemos que

$$\frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} = p_0$$

es equivalente a $\theta_{p_0} = 0$ donde

$$\theta_{p_0} = (1 - p_0) \sum_{j=1}^k \lambda_j - p_0 \sum_{j=k+1}^p \lambda_j .$$

Test para porcentajes

Observemos que

$$\frac{\sum_{j=1}^k \lambda_j}{\sum_{j=1}^p \lambda_j} = p_0$$

es equivalente a $\theta_{p_0} = 0$ donde

$$\theta_{p_0} = (1 - p_0) \sum_{j=1}^k \lambda_j - p_0 \sum_{j=k+1}^p \lambda_j .$$

Definamos el estimador de θ_{p_0}

$$\hat{\theta}_{p_0} = (1 - p_0) \sum_{j=1}^k \hat{\lambda}_j - p_0 \sum_{j=k+1}^p \hat{\lambda}_j .$$

Sea

$$\sigma_{p_0}^2 = 2(1 - p_0)^2 \sum_{j=1}^k \lambda_j^2 + 2p_0^2 \sum_{j=k+1}^p \lambda_j^2$$

Test para porcentajes

Entonces,

$$\sqrt{n}(\hat{\theta}_{p_0} - \theta_{p_0}) \xrightarrow{D} N(0, \sigma_{p_0}^2)$$

Por lo tanto, definiendo

$$\hat{\sigma}_{p_0}^2 = 2(1 - p_0)^2 \sum_{j=1}^k \hat{\lambda}_j^2 + 2p_0^2 \sum_{j=k+1}^p \hat{\lambda}_j^2$$

resulta que

$$\sqrt{n}(\hat{\theta}_{p_0} - \theta_{p_0})/\hat{\sigma}_{p_0} \xrightarrow{D} N(0, 1)$$

Test para porcentajes

Un intervalo de confianza asintótico de nivel $1 - \alpha$ para θ es

$$\mathcal{I}_{p_0} = \left[\hat{\theta}_{p_0} - \frac{\hat{\sigma}_{p_0}}{\sqrt{n}} z_{\frac{\alpha}{2}}, \hat{\theta}_{p_0} + \frac{\hat{\sigma}_{p_0}}{\sqrt{n}} z_{\frac{\alpha}{2}} \right]$$

Luego, rechazo H_{0,p_0} si $0 \notin \mathcal{I}_{p_0}$ o equivalentemente si

$$\sqrt{n} \frac{|\hat{\theta}_{p_0}|}{\hat{\sigma}_{p_0}} \geq z_{\frac{\alpha}{2}}$$

Por otra parte, un test asintótico para H_{0,p_0}^* o sea, para $H_{0,p_0}^* : \theta_{p_0} \leq 0$ versus $\theta_{p_0} > 0$ rechaza si

$$\sqrt{n} \frac{\hat{\theta}_{p_0}}{\hat{\sigma}_{p_0}} \geq z_{\alpha}$$

Ejemplo

Supongamos que nos interesa testear en un caso particular si las dos primeras componentes expresan por lo menos 80 % (85 %) de la varianza total y tenemos que

$$\frac{\hat{\lambda}_1 + \hat{\lambda}_2}{\sum_{j=1}^p \hat{\lambda}_j} = 0.8879$$

Estudiamos si vale H_{0,p_0}^*

$$H_{0,p_0}^* : \frac{\lambda_1 + \lambda_2}{\sum_{j=1}^p \lambda_j} \leq p_0 \quad \text{versus} \quad H_{1,p_0}^* : \frac{\lambda_1 + \lambda_2}{\sum_{j=1}^p \lambda_j} > p_0$$

con $p_0 = 0.80$ ($p_0 = 0.85$).

p_0	$\hat{\theta}_{p_0}$	$\hat{\sigma}_{p_0}$	$\sqrt{n} \hat{\theta}_{p_0} / \hat{\sigma}_{p_0}$	p-valor
0.80	193.778	445.38	2.853	0.0022
0.85	83.579	357.04	1.535	0.0624

Ejemplo

$$\frac{\hat{\lambda}_1 + \hat{\lambda}_2}{\sum_{j=1}^p \hat{\lambda}_j} = 0.8879$$

Estudiamos si vale H_{0,p_0}

$$H_{0,p_0} : \frac{\lambda_1 + \lambda_2}{\sum_{j=1}^p \lambda_j} = p_0 \quad \text{versus} \quad H_{1,p_0} : \frac{\lambda_1 + \lambda_2}{\sum_{j=1}^p \lambda_j} \neq p_0$$

con $p_0 = 0.90$.

p_0	$\hat{\theta}_{p_0}$	$\hat{\sigma}_{p_0}$	$\sqrt{n} \hat{\theta}_{p_0} / \hat{\sigma}_{p_0}$	p -valor	$\mathcal{I}_{p_0}$
0.90	-26.619	279.46	0.6246	0.532	(-62.213, 8.976)

Componentes Principales: Extensiones

- PCA sparse
- PCA logística (con variables binarias)
- PCA con datos faltantes
- PCA cuando los datos son curvas (datos funcionales)
- PCA robusta
- PCA con $p > n$

PCA robusta: distribuciones elípticas

Notemos que la densidad de distribución normal multivariada p -dimensional es de la forma:

$$f(\mathbf{x}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) = \frac{1}{|\boldsymbol{\Sigma}|} h(d(\mathbf{x}, \boldsymbol{\mu}, \boldsymbol{\Sigma})) \quad (1)$$

siendo $h(s) = c \exp(-s/2)$, $c = (2\pi)^{-p/2}$ y
 $d(\mathbf{x}, \boldsymbol{\mu}, \boldsymbol{\Sigma}) = (\mathbf{x} - \boldsymbol{\mu})^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})$.

Las curvas de nivel de f son superficies elipsoidales.

Las funciones f de la forma de (1), siempre que integren 1, se llaman **elípticas**.

En el caso particular en que $\boldsymbol{\mu} = \mathbf{0}$ y $\boldsymbol{\Sigma} = \text{cte } \mathbf{I}$ se llama de **simetría esférica o radial**.

PCA robusta: distribuciones elípticas

Un ejemplo importante de una distribución elíptica no normal p -dimensional es el de las distribuciones t de Student con ν ($0 < \nu < \infty$) grados de libertad que se obtiene con la elección

$$h(s) = \frac{c}{(s + \nu)^{(p+\nu)/2}} \quad (2)$$

siendo c una constante. El caso $\nu = 1$ corresponde a la Cauchy multivariada y el límite cuando $\nu \rightarrow \infty$ corresponde a la distribución normal.

Cabe destacar que si una distribución elíptica tiene media (matriz de covarianza) finita, entonces es μ (múltiplo de Σ).

PCA robusta

Supongamos que $\mathbf{X}$ tiene distribución elíptica y consideremos

$$\mathbf{Y} = \frac{\mathbf{X} - \boldsymbol{\mu}}{\|\mathbf{X} - \boldsymbol{\mu}\|}$$

$\mathbf{Y}$ es la normalización de $\mathbf{X}$ y está restringido a la superficie de esfera unidad.

Boente and Fraiman (1999) mostraron que los autovectores de $\boldsymbol{\Sigma}_{\mathbf{Y}}$, digamos $\mathbf{t}_j, j = 1 \dots p$, coinciden con los de $\boldsymbol{\Sigma}_{\mathbf{X}}$ (no los autovalores!!).

Además mostraron que dada una medida de dispersión $\sigma(\cdot)$ (por ejemplo la MAD) ocurre que $\sigma^2(\mathbf{X}^t \mathbf{t}_j)$ es proporcional a los autovalores de $\boldsymbol{\Sigma}_{\mathbf{X}}$.

Este resultado es la base de la propuesta de Locantore et al. (1999) que ofrece un enfoque simple pero efectivo, llamado SPC, *Spherical Principal Components*, que consiste en los siguiente:

PCA robusta

- Dada $\hat{\mu}$ una medida robusta de posición o centrado y calculemos

$$Y_i = \begin{cases} \frac{\mathbf{X}_i - \hat{\mu}}{\|\mathbf{X}_i - \hat{\mu}\|} & \text{si } \mathbf{X}_i \neq \hat{\mu} \\ 0 & \text{c. c.} \end{cases}$$

- Dada $\hat{\mathbf{S}}$ la matriz de covarianza muestral de los Y_i con correspondientes autovectores $\mathbf{b}_j, j = 1 \dots p$, computamos $\hat{\lambda}_j = \hat{\sigma}(\mathbf{X}^t \mathbf{b}_j)^2$, siendo $\hat{\sigma}$ un estimador robusto de dispersión, por ej. la MAD.

- Consideramos $\hat{\lambda}_{(j)}$ ordenados, es decir $\hat{\lambda}_{(1)} \geq \hat{\lambda}_{(2)} \dots \geq \hat{\lambda}_{(p)}$ y $\mathbf{b}_{(j)}$ los correspondientes autovectores.
- Las primeras k direcciones principales están dadas por $\mathbf{b}_{(j)}, 1 \leq j \leq k$ y las respectivas proporciones de varianza no explicada se calculan a partir de $\hat{\lambda}_{(j)}$.
- Una elección sencilla para computar un estimador de μ está dado por

$$\hat{\mu} = \operatorname{argmin} \sum_{i=1}^n \|\mathbf{X}_i - \hat{\mu}\|$$

PCA en alta dimensión: $n < p$

En algunos casos ocurre que el tamaño muestral n es menor que p , la dimensión de las variables: microarrays, imágenes, etc.

Como antes, asumamos que las $\mathbf{X}_i$ están centradas.

Notemos que si $n < p$ entonces el subespacio lineal sobre el que podemos proyectar es a lo sumo $n - 1$.

PCA en alta dimensión: $n < p$

Tenemos que $\widehat{\Sigma} = \frac{1}{n} \mathbf{X}^t \mathbf{X}$ y además $\widehat{\Sigma} \widehat{\gamma}_j = \widehat{\lambda}_j \widehat{\gamma}_j$. Por lo tanto:

$$\frac{1}{n} \mathbf{X}^t \mathbf{X} \widehat{\gamma}_j = \widehat{\lambda}_j \widehat{\gamma}_j$$

$$\frac{1}{n} \mathbf{X} \mathbf{X}^t \mathbf{X} \widehat{\gamma}_j = \widehat{\lambda}_j \mathbf{X} \widehat{\gamma}_j \quad \text{multiplicando por izq. por } \mathbf{X}$$

$$\frac{1}{n} \mathbf{X} \mathbf{X}^t \underbrace{\mathbf{X} \widehat{\gamma}_j}_{\text{rojo}} = \widehat{\lambda}_j \underbrace{\mathbf{X} \widehat{\gamma}_j}_{\text{rojo}}$$

$$\frac{1}{n} \mathbf{X} \mathbf{X}^t \mathbf{v}_j = \widehat{\lambda}_j \mathbf{v}_j$$

PCA en alta dimensión: $n < p$

Tenemos que $\widehat{\Sigma} = \frac{1}{n} \mathbf{X}^t \mathbf{X}$ y además $\widehat{\Sigma} \widehat{\gamma}_j = \widehat{\lambda}_j \widehat{\gamma}_j$. Por lo tanto:

$$\frac{1}{n} \mathbf{X}^t \mathbf{X} \widehat{\gamma}_j = \widehat{\lambda}_j \widehat{\gamma}_j$$

$$\frac{1}{n} \mathbf{X} \mathbf{X}^t \mathbf{X} \widehat{\gamma}_j = \widehat{\lambda}_j \mathbf{X} \widehat{\gamma}_j \quad \text{multiplicando por izq. por } \mathbf{X}$$

$$\frac{1}{n} \mathbf{X} \mathbf{X}^t \underbrace{\mathbf{X} \widehat{\gamma}_j}_{\mathbf{v}_j} = \widehat{\lambda}_j \underbrace{\mathbf{X} \widehat{\gamma}_j}_{\mathbf{v}_j}$$

$$\frac{1}{n} \mathbf{X} \mathbf{X}^t \mathbf{v}_j = \widehat{\lambda}_j \mathbf{v}_j$$

Multiplicando por izquierda por $\mathbf{X}^t$ queda

$$\frac{1}{n} \mathbf{X}^t \mathbf{X} \underbrace{\mathbf{X}^t \mathbf{v}_j}_{\mathbf{X}^t \mathbf{v}_j} = \widehat{\lambda}_j \underbrace{\mathbf{X}^t \mathbf{v}_j}_{\mathbf{X}^t \mathbf{v}_j}$$

con lo que $\mathbf{X}^t \mathbf{v}_j$ es un autovector de $\frac{1}{n} \mathbf{X}^t \mathbf{X}$.

PCA en alta dimensión: $n < p$

Pero $\mathbf{X}^t \mathbf{v}_j$ es un autovector que puede no estar normalizado:

$\hat{\gamma}_j \propto \mathbf{X}^t \mathbf{v}_j$, con lo cual $\hat{\gamma}_j = \text{cte } \mathbf{X}^t \mathbf{v}_j$:

$$1 = \hat{\gamma}_j^t \hat{\gamma}_j$$

$$1 = \text{cte}^2 \mathbf{v}_j^t \mathbf{X} \mathbf{X}^t \mathbf{v}_j$$

$$1 = \text{cte}^2 n \mathbf{v}_j^t \frac{\mathbf{X} \mathbf{X}^t}{n} \mathbf{v}_j$$

$$1 = \text{cte}^2 n \hat{\lambda}_j \mathbf{v}_j^t \mathbf{v}_j$$

$$1 = \text{cte}^2 n \hat{\lambda}_j$$

con lo que $\text{cte} = 1/\sqrt{n \hat{\lambda}_j}$

PCA en alta dimensión: $n < p$

- centramos las $\mathbf{X}_i$
- evaluamos $\mathbf{X}\mathbf{X}^t/n$
- calculamos sus autovalores y autovectores
- computamos $\hat{\gamma}_j = 1/\sqrt{n\hat{\lambda}_j} \mathbf{X}^t \mathbf{v}_j$