

Componentes Principales aplicado a Clasificación


Datos de Wisconsin: Breast Cancer Data

- 569 observaciones con 30 características de imágenes digitalizadas de punciones de tumores de mama. La respuesta indica si el tumor es benigno o no.
-

Componentes Principales aplicado a Clasificación

[1]	"id"	"diagnosis"
[3]	"radius_mean"	"texture_mean"
[5]	"perimeter_mean"	"area_mean"
[7]	"smoothness_mean"	"compactness_mean"
[9]	"concavity_mean"	"concave.points_mean"
[11]	"symmetry_mean"	"fractal_dimension_mean"
[13]	"radius_se"	"texture_se"
[15]	"perimeter_se"	"area_se"
[17]	"smoothness_se"	"compactness_se"
[19]	"concavity_se"	"concave.points_se"
[21]	"symmetry_se"	"fractal_dimension_se"
[23]	"radius_worst"	"texture_worst"
[25]	"perimeter_worst"	"area_worst"
[27]	"smoothness_worst"	"compactness_worst"
[29]	"concavity_worst"	"concave.points_worst"
[31]	"symmetry_worst"	"fractal_dimension_worst"
[33]	"X"	

Componentes Principales aplicado a Clasificación



Componentes Principales aplicado a Regresión Lineal (PCR)

El método Principal Components Regression (PCR) consiste en ajustar un modelo de regresión lineal por mínimos cuadrados empleando como predictores las componentes generadas a partir de un análisis de componentes principales (PCA).

Muchas veces se dispone de un número elevado de variables que se pueden emplear como predictores, pero un alto número de predictores no implica necesariamente mucha información.

Si hay alta correlación entre las variables la información que aportan es redundante y viola la condición de no colinealidad.

Componentes Principales aplicado a Regresión Lineal (PCR)

Si bien el análisis de componentes principales reduce el número de predictores del modelo, no selecciona variables.

Todas las variables se usan para calcular las componentes principales.

El método PCR no deja de ser un ajuste lineal por mínimos cuadrados que emplea componentes principales como predictores.

PCR: Datos meatspec del paquete faraway.

Contenido en grasa: se emplea un espectrofotómetro que detecta la absorbancia que tiene un material a diferentes tipos de luz en función de sus características.

Se mide el espectro de absorbancia de 100 longitudes de onda en 215 muestras de carne. Esto está en las primeras 100 columnas ($V_1, \dots, V_{100}$)

Por un análisis químico se obtiene el contenido de grasa. La columna `fat` 101.

Se dividen las observaciones disponibles en dos grupos: uno de entrenamiento para ajustar el modelo ($\approx 80\%$) y uno de test ($\approx 20\%$). Para evaluar la predicción de la variable `fat`.

PCR: Datos meatspec del paquete faraway.

- Ajustamos un modelo incluyendo todas las longitudes de onda como predictores en la muestra de entrenamiento.
- Error de predicción 0.48 cuando predecimos usando las mismas observaciones con las que se ha entrenado.
- Error de predicción con la muestra de testing 21.62, 45 veces más alto.
- Posiblemente estemos ante un problema de overfitting. Esto puede deberse por tener muchas predictoras: n bajo respecto de p .

	PC1	PC2	PC3	PC4	PC5	PC6	PC7	PC8	PC9
Std. dev.	5.0166	0.5091	0.2838	0.1675	0.0389	0.0248	0.015	0.011	0.005
Prop. Var.	0.9855	0.0101	0.0032	0.0011	0.0001	0.0000	0.000	0.000	0.000
Cum. Prop.	0.9855	0.9956	0.9988	0.9999	1.0000	1.0000	1.000	1.000	1.000

PCR: Datos meatspec del paquete faraway.

- Ajustamos el modelo usando componentes principales.
- Las primeras cuatro componentes explican el 99.99100 % de varianza.
- La función `calcular` las componentes y hacemos la regresión
- El error de predicción en la muestra de testing es 21.93. que es parecido al que teníamos incluyendo todas las predictoras. ¿Qué falla?? ¿Qué podemos hacer?

PCR: Datos meatspec del paquete faraway.

- Ajustamos el modelo usando componentes principales.
- Las primeras cuatro componentes explican el 99.99100 % de varianza.
- La función calculamos las componentes y hacemos la regresión
- El error de predicción en la muestra de testing es 21.93. que es parecido al que teníamos incluyendo todas las predictoras. ¿Qué falla??¿Qué podemos hacer?
- Podemos hacer cross validation para elegir el número de componentes óptimo que minimice el error de predicción.

PCR: Datos meatspec del paquete faraway.

- Ajustamos el modelo aplicando componentes principales y eligiendo el número de por CV.
- Elegimos el número de componentes y se obtiene un error de predicción en la muestra de entrenamiento muchísimo menor!
A probar!



PCR

- ¿Por qué con 4 componentes no funcionaba si explicaba el 99 %?
- Siempre podremos obtener una buena reducción para explicar una variables de respuesta?

Veamos unos ejemplos en gráficos y en R.



Ejemplo

Veamos este ejemplo (X_1, X_2, Y) .




Gracias Lili Forzani!


Ejemplo



Ejemplo



Ejemplo



Ejemplo

