

Análisis Discriminante - Clasificación

Tiene dos objetivos:

- **Discriminar:** es decir construir un clasificador o una regla de clasificación que permita separar las clases lo mejor posible.
- **Clasificar:** dada un nuevo conjunto de variables sin etiquetas usar el clasificador para predecir la clase.

En **machine learning** se la conoce como aprendizaje supervisado. La diferencia fundamental con los métodos que vimos es que, como en regresión, tenemos una variable de respuesta que en este caso son las clases.

Clasificador

- Información disponible $\mathbf{x} \in \mathcal{X}$.
- Posibles *etiquetas*. Caso binario $\mathcal{Y} = \{0, 1\}$
- Posibles *etiquetas*. Caso general $\mathcal{Y} = \{c_1, \dots, c_M\}$
- Clasificador: Regla que asigna a $\mathbf{x} \in \mathcal{X}$ un posible valor $y \in \mathcal{Y}$.

Clasificación: Marco Teórico

- $\mathbf{X} \in \mathcal{X}, Y \in \mathcal{Y}$.
- $(\mathbf{X}, Y)$ vector aleatorio, con puntual p_{XY} .
- Clasificador: Regla (de clasificación) que asigna a cada $\mathbf{x} \in \mathcal{X}$ un elemento $y \in \mathcal{Y}$

Clasificador $g : \mathcal{X} \rightarrow \mathcal{Y}$

- Función de pérdida es de tipo 0-1:

$$L(a, b) = \mathbb{I}(a \neq b)$$

- Error de Clasificación Medio (verdadero - poblacional) del clasificador g

$$\mathbb{E}(L(g(\mathbf{X}), Y)) = \mathbb{P}(g(\mathbf{X}) \neq Y)$$

- Objetivo (teórico): Encontrar g que minimice el error de clasificación medio


$$g^{op}$$

g^{op} Optimo: Regla de Bayes - Caso binario

$$g^{op}(\mathbf{x}) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) \geq \mathbb{P}(Y = 0 \mid \mathbf{X} = \mathbf{x}) \\ 0 & \text{si } \mathbb{P}(Y = 0 \mid \mathbf{X} = \mathbf{x}) > \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) \end{cases}$$

Teorema: $\mathbb{P}(g^{op}(\mathbf{X}) \neq Y) \leq \mathbb{P}(g(\mathbf{X}) \neq Y)$, para todo g .

Clasificador de Bayes



En otras palabras, si conociéramos la verdadera distribución condicional $P(Y|\mathbf{X})$ podríamos computar el clasificador óptimo bajo una pérdida de tipo 0-1.

El clasificador óptimo de Bayes predice:

$$\hat{Y} = \underset{j=0,1}{\operatorname{argmax}} \mathbb{P}(Y = c_j | \mathbf{X} = \mathbf{x})$$

En la práctica, tendremos que estimar estas probabilidades condicionales

Clasificador de Bayes: más de 2 clases

Cuando tenemos M clases, $c_1, c_2, \dots, c_M$ y buscamos minimizar la esperanza de pérdida 0-1, buscamos g^{op} que para todo clasificador $g : \mathcal{X} \rightarrow \{c_1, \dots, c_M\}$ cumpla

$$\mathbb{E}(L(g^{op}(\mathbf{X}), Y)) \leq \mathbb{E}(L(g(\mathbf{X}), Y))$$

Tenemos que

$$\begin{aligned}\mathbb{E}(L(g^{op}(\mathbf{X}), Y)) &= \mathbb{E}_{XY}(L(g^{op}(\mathbf{X}), Y)) \\ &= \mathbb{E}_X(\mathbb{E}[L(g^{op}(\mathbf{X}), Y) | \mathbf{X}]) \\ &= \mathbb{E}_X \left(\sum_{j=1}^M L(g^{op}(\mathbf{X}), c_j) \mathbb{P}(Y = c_j | \mathbf{X}) \right)\end{aligned}$$

Clasificador de Bayes: más de 2 clases

Alcanza con encontrar g^{op} que minimice

$$\begin{aligned}\sum_{j=1}^M L(g^{op}(\mathbf{X}), c_j) \mathbb{P}(Y = c_j | \mathbf{X}) &= \sum_{c_j \neq g^{op}(\mathbf{X})}^M \mathbb{P}(Y = c_j | \mathbf{X}) \\ &= 1 - \mathbb{P}(Y = g^{op}(\mathbf{X}) | \mathbf{X})\end{aligned}$$

Con lo cual el clasificador óptimo cumple

$$\mathbb{P}(Y = g^{op}(\mathbf{X}) | \mathbf{X}) \geq \mathbb{P}(Y = c_j | \mathbf{X})$$

por lo tanto $g^{op}(\mathbf{X})$ debe ser la clase con mayor probabilidad condicional dado $\mathbf{X}$:

$$\hat{Y} = \operatorname{argmax}_j \mathbb{P}(Y = c_j | \mathbf{X} = \mathbf{x})$$

g^{op} Optimo: Regla de Bayes - Caso binario

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) \geq \mathbb{P}(Y = 0 \mid \mathbf{X} = \mathbf{x}) \\ 0 & \text{si } \mathbb{P}(Y = 0 \mid \mathbf{X} = \mathbf{x}) > \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) \end{cases}$$

Notemos que

$$\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) \geq \mathbb{P}(Y = 0 \mid \mathbf{X} = \mathbf{x}) \Leftrightarrow \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) \geq 1/2$$

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) \geq 1/2 \\ 0 & \text{c. c.} \end{cases}$$

g^{op} Optimo: Regla de Bayes - Caso binario

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) \geq \mathbb{P}(Y = 0 \mid \mathbf{X} = \mathbf{x}) \\ 0 & \text{si c. c.} \end{cases}$$

De Bayes, tenemos que, si $\mathbf{X}$ es discreta, en un x de masa positiva

$$\mathbb{P}(Y = y \mid \mathbf{X} = \mathbf{x}) = \frac{\mathbb{P}(\mathbf{X} = \mathbf{x} \mid Y = y) \mathbb{P}(Y = y)}{\mathbb{P}(\mathbf{X} = \mathbf{x})}$$

$$g^{op}(\mathbf{x}) = \begin{cases} 1 & \text{si } \mathbb{P}(\mathbf{X} = \mathbf{x} \mid Y = 1) \mathbb{P}(Y = 1) \geq \mathbb{P}(\mathbf{X} = \mathbf{x} \mid Y = 0) \mathbb{P}(Y = 0) \\ 0 & \text{si } \mathbb{P}(\mathbf{X} = \mathbf{x} \mid Y = 0) \mathbb{P}(Y = 0) > \mathbb{P}(\mathbf{X} = \mathbf{x} \mid Y = 1) \mathbb{P}(Y = 1) \end{cases}$$

g^{op} Optimo: Regla de Bayes - Caso binario

$$g^{op}(x) = \begin{cases} 1 & \text{si } \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) \geq \mathbb{P}(Y = 0 \mid \mathbf{X} = \mathbf{x}) \\ 0 & \text{si c. c.} \end{cases}$$

De Bayes, tenemos que, si $\mathbf{X}$ es discreta, en un x de masa positiva

$$\mathbb{P}(Y = y \mid \mathbf{X} = \mathbf{x}) = \frac{\mathbb{P}(\mathbf{X} = \mathbf{x} \mid Y = y) \mathbb{P}(Y = y)}{\mathbb{P}(\mathbf{X} = \mathbf{x})}$$

$$g^{op}(\mathbf{x}) = \begin{cases} 1 & \text{si } \mathbb{P}(\mathbf{X} = \mathbf{x} \mid Y = 1) \mathbb{P}(Y = 1) \geq \mathbb{P}(\mathbf{X} = \mathbf{x} \mid Y = 0) \mathbb{P}(Y = 0) \\ 0 & \text{si } \mathbb{P}(\mathbf{X} = \mathbf{x} \mid Y = 0) \mathbb{P}(Y = 0) > \mathbb{P}(\mathbf{X} = \mathbf{x} \mid Y = 1) \mathbb{P}(Y = 1) \end{cases}$$

En el caso continuo, si $p_j = P(Y = c_j)$, $\mathbf{X} \mid Y = 0 \sim f_0$ y $\mathbf{X} \mid Y = 1 \sim f_1$, resulta

$$g^{op}(x) = \begin{cases} 1 & \text{si } f_1(\mathbf{x}) p_1 \geq f_0(\mathbf{x}) p_0 \\ 0 & \text{si c. c.} \end{cases}$$

Regla óptima de Bayes

¿Cómo hacemos cuando no conocemos estas densidades o probabilidades?

- Mucho métodos surgen de estimar densidades

$$g^{op}(\mathbf{x}) = \operatorname{argmax}_{1 \leq j \leq M} f_j(\mathbf{x})p_j$$

- otros surgen de estimar las probabilidades condicionales

$$g^{op}(\mathbf{x}) = \operatorname{argmax}_{1 \leq j \leq M} \mathbb{P}(Y = c_j | \mathbf{X} = \mathbf{x})$$

Regla óptima de Bayes

Vamos a estimar en función de la muestra. Fundamentalmente en base a qué se estima surgen distintos métodos clasificación:

- knn
- Regresión Logística
- Bayes Naive
- LDA
- QDA

Evaluación de un clasificador


- Muestra: $(\mathbf{X}_1, Y_1), (\mathbf{X}_2, Y_2), \dots, (\mathbf{X}_n, Y_n)$
- Muestra de testeo: $(\mathbf{X}_1, Y_1), (\mathbf{X}_2, Y_2), \dots, (\mathbf{X}_m, Y_m)$
- Error Empírico de Clasificación: $\frac{1}{m} \sum_{j=1}^m \mathbb{I}(\hat{Y}_j \neq Y_j)$

Estimando Probabilidades

k nn: k —Vecinos más cercanos

El método de k —Vecinos más cercanos asigna por la mayoría.

En el ejemplo, para asignar un color con $k = 3$ buscamos los 3 vecinos más cercanos al punto de interés y predecimos el color con el de la mayoría de los k vecinos.



k nn: k —Vecinos más cercanos

El método de k —Vecinos más cercanos es uno de los métodos existentes para estimar la distribución condicional de Y dado $\mathbf{X}$ y para después clasificar una observación en la clase con la mayor probabilidad estimada.


- Elegimos k un entero positivo y un punto $\mathbf{x}$ para clasificar.
- El clasificador k nn identifica el conjunto de los k puntos más cercanos a $\mathbf{x}$. Sea N_x dicho conjunto.
- Estima a $\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$ por la fracción de puntos en N_x cuya etiqueta es igual a 1:

$$\hat{\mathbb{P}}(Y = 1 \mid \mathbf{X} = \mathbf{x}) = \frac{1}{k} \sum_{i \in N_x} \mathcal{I}_{\{y_i=1\}}$$


- Análogamente estimamos $\mathbb{P}(Y = 0 \mid \mathbf{X} = \mathbf{x})$ (o las demás si son más de dos clases).

k nn: k —Vecinos más cercanos

$k = 1$




$k = 100$




k nn: k —Vecinos más cercanos

$k = 1$




$k = 100$




¿Cómo elegimos el parámetro k ?

k nn: k —Vecinos más cercanos

$k = 1$



$k = 100$



¿Cómo elegimos el parámetro k ? **Por CV!!**

Vayamos a R a ver un ejemplo

Vasoconstriction Data

39 observaciones con variables:

Volume: Inhaled volume of air

Rate: Rate of inhalation

Y: vector of 0 or 1 values.

Modelamos las probabilidades condicionales

La regla de óptima de Bayes depende de:

$$p(\mathbf{x}) = \mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x})$$

$\mathbf{X} = (X_1, \dots, X_q)^t$ es un vector de p covariables.

¿Y si modelamos esta probabilidad en función de $\mathbf{X}$?

Tenemos que tener algunos cuidados...

Regresión Logística

Empecemos por una sola variable X y notemos que

$$0 \leq p(x) \leq 1$$

¿Podemos modelar $p(x) = \beta_0 + \beta_1 x$???

Regresión Logística

Empecemos por una sola variable X y notemos que

$$0 \leq p(x) \leq 1$$

Sin embargo, los **odds**

$$\frac{p(x)}{1 - p(x)} \geq 0$$

Regresión Logística

Empecemos por una sola variable X y notemos que

$$0 \leq p(x) \leq 1$$

Sin embargo, los **odds**

$$\frac{p(x)}{1 - p(x)} \geq 0$$

Tomando logaritmo:

$$-\infty < \log \left(\frac{p(x)}{1 - p(x)} \right) < \infty$$

Podríamos modelar:

$$\log \left(\frac{p(x)}{1 - p(x)} \right) = \beta_0 + \beta_1 x$$

Regresión Logística

Empecemos por una sola variable X y notemos que

$$0 \leq p(x) \leq 1$$

Sin embargo, los **odds**

$$\frac{p(x)}{1 - p(x)} \geq 0$$

Tomando logaritmo:

$$-\infty < \log\left(\frac{p(x)}{1 - p(x)}\right) < \infty$$

Podríamos modelar:

$$\log\left(\frac{\mathbb{P}(Y = 1 \mid X = x)}{\mathbb{P}(Y = 0 \mid X = x)}\right) = \beta_0 + \beta_1 x$$

Regresión Logística

Haciendo el camino inverso:

$$\frac{p(x)}{1 - p(x)} = e^{\beta_0 + \beta_1 x}$$

$$p(x) = p(x, \beta) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}}$$

Regresión Logística

Haciendo el camino inverso:

$$\frac{p(x)}{1 - p(x)} = e^{\beta_0 + \beta_1 x}$$

$$p(x) = p(x, \beta) = \frac{e^{\beta_0 + \beta_1 x}}{1 + e^{\beta_0 + \beta_1 x}} = \frac{1}{1 + e^{-\beta_0 - \beta_1 x}}$$

Regresión Logística

En general:

$$\mathbb{P}(Y = 1 \mid \mathbf{X} = \mathbf{x}) = \frac{e^{\beta_1 x_1 + \dots + \beta_q x_q}}{1 + e^{\beta_1 x_1 + \dots + \beta_q x_q}}$$

Estamos proponiendo un modelo para la distribución condicional:

$$Y|_{\mathbf{X}=\mathbf{x}} \sim Bi(1, p(\mathbf{x}, \boldsymbol{\beta}))$$

Regresión Logística: Estimación

$(Y_1, \mathbf{X}_1), \dots, (Y_n, \mathbf{X}_n)$ independientes donde $Y_i | \mathbf{X}_i = \mathbf{x} \sim Bi(1, p(\mathbf{x}, \boldsymbol{\beta}))$

El estimador clásico en este contexto se obtiene por el método de máxima verosimilitud, es decir hallando $\mathbf{b} = (b_1, b_2, \dots, b_q)^t$ que maximizan $L(\mathbf{b}) = L(\mathbf{b}; y_1, \dots, y_n, \mathbf{x}_1, \dots, \mathbf{x}_n)$ donde

$$L(\mathbf{b}; y_1, \dots, y_n, \mathbf{x}_1, \dots, \mathbf{x}_n) = \prod_{i=1}^n p(\mathbf{x}_i, \mathbf{b})^{y_i} (1 - p(\mathbf{x}_i, \mathbf{b}))^{1-y_i}$$

Regresión Logística: Máxima Verosimilitud

$\hat{\beta}$ resulta de maximizar

$$\log L(\mathbf{b}) = \sum_{i=1}^n y_i \log(p(\mathbf{x}_i, \mathbf{b})) + (1 - y_i) \log(1 - p(\mathbf{x}_i, \mathbf{b}))$$

Regresión Logística: Máxima Verosimilitud

$\hat{\beta}$ resulta de maximizar

$$\log L(\mathbf{b}) = \sum_{i=1}^n y_i \log(p(\mathbf{x}_i, \mathbf{b})) + (1 - y_i) \log(1 - p(\mathbf{x}_i, \mathbf{b}))$$

o minimizar

$$\sum_{i=1}^n - (y_i \log(p(\mathbf{x}_i, \mathbf{b})) + (1 - y_i) \log(1 - p(\mathbf{x}_i, \mathbf{b}))) = \sum_{i=1}^n d(y_i, \mathbf{x}_i, \mathbf{b})$$

relacionado con la deviance y con la cross-entropy.

Este estimador no tiene una expresión analítica.

Se halla derivando e igualando a 0 la log-verosimilitud y resolviendo numéricamente la ecuación por el método de Newton-Raphson.

Vayamos a R a ver el ejemplo

Vasoconstriction Data

Regresión Logística: Máxima Verosimilitud

1. Podemos computar un estimador del standard error de cada $\hat{\beta}_j$: $SE(\hat{\beta}_j)$.
2. Se puede considerar el estadístico $\frac{\hat{\beta}_j}{SE(\hat{\beta}_j)}$ para testear que cada coeficiente: $H_o : \beta_j = 0$ vs. $H_1 : \beta_j \neq 0$. Para n suficientemente grande la distribución bajo H_o es aproximadamente normal standard. (ver salida de R).
3. Las estimaciones de los coeficientes son inestables cuando hay colinealidad.
4. El estimador de máxima verosimilitud no existe cuando las clases están perfectamente separadas por un plano.

Simulación

(Tesis Doc. Gonzalo Chebi, 2019)

Consideremos ahora el siguiente estudio de simulación:

- Elegimos muestras de entrenamiento y de testeo $n = \tilde{n} = 150$ y la dimensión de las covariables $q \in \{5, 10, 15, \dots, 115, 120\}$.
- El vector $\beta \in \mathbb{R}^q$ elegido es tal que $(\beta)_j = \mathbb{I}_{j \leq 5}$, es decir, sus primeras 5 coordenadas son 1 y el resto son 0 (escenario esparso).
- Las covariables $\mathbf{X}_i \sim N(\mathbf{0}, \mathbf{I}_q)$ y las variables Y_i son independientes con distribución condicional $Y_i | \mathbf{X}_i \sim Bi(1, p(\mathbf{X}_i, \beta))$.
- Para cada q , realizamos 400 replicaciones en donde obtenemos el estimador $\hat{\beta}$ y calculamos la proporción de clasificaciones correctas dentro y fuera de la muestra.
- Finalmente, promediamos los 400 resultados, obteniendo el siguiente gráfico.

Simulación (Tesis Doc. Gonzalo Chebi, 2019)




Figura : Proporción de clasificaciones correctas dentro y fuera de la muestra con $n = 150$ y $(\beta_0)_j = \mathbb{I}_{j \leq 5}$. Cada uno de los puntos corresponde al promedio sobre 400 replicaciones. Los círculos rojos y los triángulos celestes indican la proporción de clasificaciones correctas dentro y fuera de la muestra, respectivamente.

Métodos de Regularización

Como en el modelo lineal los métodos de regularización pueden ayudarnos a evitar el sobreajuste y a seleccionar variables.

$$\begin{aligned} & \sum_{i=1}^n - (y_i \log(p(\mathbf{x}_i, \mathbf{b})) + (1 - y_i) \log(1 - p(\mathbf{x}_i, \mathbf{b}))) + \lambda I(\boldsymbol{\beta}) \\ = & \sum_{i=1}^n d(y_i, \mathbf{x}_i, \mathbf{b}) + \lambda I(\boldsymbol{\beta}) \end{aligned}$$

donde $I(\boldsymbol{\beta})$ es una penalización.

Hemos visto las penalizaciones Ridge y LASSO que corresponden a $I(\boldsymbol{\beta}) = \|\boldsymbol{\beta}\|_2^2$ e $I(\boldsymbol{\beta}) = \|\boldsymbol{\beta}\|_1$, respectivamente .

Métodos de Regularización

$$\begin{aligned}\sum_{i=1}^n & - [y_i \log(p(\mathbf{x}_i, \mathbf{b})) + (1 - y_i) \log(1 - p(\mathbf{x}_i, \mathbf{b}))] + \lambda I(\boldsymbol{\beta}) \\ & = \sum_{i=1}^n d(y_i, \mathbf{x}_i, \mathbf{b}) + \lambda I(\boldsymbol{\beta})\end{aligned}$$

Penalización **Elastic Net**: tenemos que para $\alpha \in [0, 1]$

$$I(\boldsymbol{\beta}) = \{\alpha \|\boldsymbol{\beta}\|_1 + (1 - \alpha)/2 \|\boldsymbol{\beta}\|_2^2\}$$

- El usuario elige α .
- Cuando $\alpha = 0$ se reduce a Ridge y si $\alpha = 1$ se reduce a LASSO.
- **Elastic Net** permite realizar selección de variables si $\alpha > 0$ y arroja mejores resultados que la penalización LASSO cuando hay un alto grado de colinealidad entre las variables.

Estimando Densidades

Enfoque No Paramétrico: Bayes Naive

Una forma de eludir el problema de la maldición de la dimensión es construir un estimador bajo la hipótesis de que las p covariables son independientes. Luego, pensamos que

$$d(\mathbf{x}) = d_1(x_1) d_2(x_2) \dots d_p(x_p)$$

y estimamos:

$$\hat{d}(\mathbf{x}) = \hat{d}_1(x_1) \hat{d}_2(x_2) \dots \hat{d}_p(x_p)$$

Enfoque No Paramétrico: Bayes Naive

Una forma de eludir el problema de la maldición de la dimensión es construir un estimador bajo la hipótesis de que las p covariables son independientes. Luego, pensamos que

$$d(\mathbf{x}) = d_1(x_1) d_2(x_2) \dots d_p(x_p)$$

y estimamos:

$$\hat{d}(\mathbf{x}) = \hat{d}_1(x_1) \hat{d}_2(x_2) \dots \hat{d}_p(x_p)$$

Es decir, en lugar de estimar la densidad multivariada de $\mathbf{X} = (\text{altura, peso, perímetro de caderas, perímetro de cintura})$.

Estimamos de forma separada la densidad de $X_1 = \text{altura}$, $X_2 = \text{peso}$, $X_3 = \text{perímetro de caderas}$ y $X_4 = \text{perímetro de cintura}$.

Bayes Naive

Así, obtenemos $\hat{f}_1(\mathbf{x})$ y $\hat{f}_0(\mathbf{x})$ y con esto armamos el clasificador.

$$\hat{g}(\mathbf{x}) = \begin{cases} 1 & \text{si } \hat{f}_1(\mathbf{x})\hat{p}_1 \geq \hat{f}_0(\mathbf{x})\hat{p}_0, \\ 0 & \text{si c.c.} \end{cases}$$

Clasificación: Un modelo para $\mathbf{X}|Y = c_j$

Como vimos

$$g^{op}(x) = \operatorname{argmax}_{j=0,1} f_j(\mathbf{x})p_j$$

en el caso binario equivalente a

$$g^{op}(\mathbf{x}) = \begin{cases} 1 & \text{si } f_1(\mathbf{x})p_1 \geq f_0(\mathbf{x})p_0, \\ 0 & \text{si c.c.} \end{cases}$$

Podríamos modelar la distribución de $\mathbf{X}|Y$, por ejemplo, asumiendo

$$\mathbf{X}|Y = c_j \sim N(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)$$

o dicho de otra forma

$$f_j(\mathbf{x}) \sim N(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)$$

Clasificación: Un modelo para $\mathbf{X}|Y = c_j$

El clasificador asignará a la clase 1 si

$$\frac{\exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_1)^t \boldsymbol{\Sigma}_1^{-1} (\mathbf{x} - \boldsymbol{\mu}_1) \right\}}{(2\pi)^{p/2} [\det (\boldsymbol{\Sigma}_1)]^{\frac{1}{2}}} p_1 \geq \frac{\exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_0)^t \boldsymbol{\Sigma}_0^{-1} (\mathbf{x} - \boldsymbol{\mu}_0) \right\}}{(2\pi)^{p/2} [\det (\boldsymbol{\Sigma}_0)]^{\frac{1}{2}}} p_0$$

Clasificación: Un modelo para $\mathbf{X}|Y = c_j$

El clasificador asignará a la clase 1 si

$$\frac{\exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_1)^t \boldsymbol{\Sigma}_1^{-1} (\mathbf{x} - \boldsymbol{\mu}_1) \right\}}{(2\pi)^{p/2} [\det (\boldsymbol{\Sigma}_1)]^{\frac{1}{2}}} p_1 \geq \frac{\exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_0)^t \boldsymbol{\Sigma}_0^{-1} (\mathbf{x} - \boldsymbol{\mu}_0) \right\}}{(2\pi)^{p/2} [\det (\boldsymbol{\Sigma}_0)]^{\frac{1}{2}}} p_0$$

- $\boldsymbol{\Sigma}_1 = \boldsymbol{\Sigma}_0 \rightsquigarrow$ Análisis Discriminante Lineal (LDA)
- $\boldsymbol{\Sigma}_1 \neq \boldsymbol{\Sigma}_0 \rightsquigarrow$ Análisis Discriminante Cuadrático (QDA)

Clasificación: $\Sigma_1 = \Sigma_0 \rightsquigarrow$ LDA

El clasificador quedará que clasifica en la variedad 1 si

$$\frac{\exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_1)^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}_1) \right\}}{(2\pi)^{p/2} [\det (\boldsymbol{\Sigma})]^{\frac{1}{2}}} p_1 \geq \frac{\exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_0)^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}_0) \right\}}{(2\pi)^{p/2} [\det (\boldsymbol{\Sigma})]^{\frac{1}{2}}} p_0$$

Clasificación: Discriminación Lineal

Si consideramos las formas cuadráticas

$$D_1 = (x - \mu_1)^t \Sigma^{-1} (x - \mu_1) \quad D_0 = (x - \mu_0)^t \Sigma^{-1} (x - \mu_0)$$

notamos que la regla depende de la distancia de Mahalanobis.

Clasificación: Discriminación Lineal

Si cada variedad es una variable $N(\boldsymbol{\mu}_1, \boldsymbol{\Sigma})$ y $N(\boldsymbol{\mu}_0, \boldsymbol{\Sigma})$, entonces se clasifica en la variedad 1 si

$$\mathbf{w}^t \mathbf{x} \leq \mathbf{w}^t \frac{\boldsymbol{\mu}_0 + \boldsymbol{\mu}_1}{2} - \log(p_0/p_1)$$

con $\mathbf{w} = \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)$

Clasificación: Discriminación Lineal

Si cada variedad es una variable $N(\boldsymbol{\mu}_1, \boldsymbol{\Sigma})$ y $N(\boldsymbol{\mu}_0, \boldsymbol{\Sigma})$, entonces se clasifica en la variedad 1 si

$$\mathbf{w}^t \mathbf{x} \leq \mathbf{w}^t \frac{\boldsymbol{\mu}_0 + \boldsymbol{\mu}_1}{2} - \log(p_0/p_1)$$

con $\mathbf{w} = \boldsymbol{\Sigma}^{-1}(\boldsymbol{\mu}_0 - \boldsymbol{\mu}_1)$

Notemos que la frontera como función de los *features* es de la forma

$$\mathbf{a}^t \mathbf{x} + b = 0$$

Luego, el clasificador corresponde a la ecuación de un hiperplano, es decir hay un hiperplano que separa a quien clasifica en la variedad 1 y a quien en la 0 (de ahí el nombre de clasificador lineal).

¿Cómo estimamos?

Si no conocemos μ_1 , μ_0 y $\Sigma \rightarrow \rightarrow$ los estimamos!

$$\hat{\mu}_1, \hat{\mu}_0 \text{ y } \hat{\Sigma}_{pooled} = \frac{(n_1 - 1)\mathbf{S}_1 + (n_0 - 1)\mathbf{S}_0}{n_1 + n_0 - 2}$$

$$\text{donde } \mathbf{S}_i = \frac{n_i}{n_i - 1} \hat{\Sigma}$$

Los estimadores de máxima verosimilitud de la media y la matriz de covarianzas son

- $\hat{\mu} = \bar{\mathbf{X}} = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i$
- $\hat{\Sigma} = \frac{1}{n} \sum_{i=1}^n (\mathbf{X}_i - \bar{\mathbf{X}})(\mathbf{X}_i - \bar{\mathbf{X}})^t$

Volvamos al ejemplo.

Clasificación: Poblaciones Gaussianas

$$f_1(\mathbf{x})p_1 > f_0(\mathbf{x})p_0$$

es equivalente a

$$\log \left(\frac{f_1(\mathbf{x})p_1}{f_0(\mathbf{x})p_0} \right) > 0$$

es equivalente a

$$\mathbf{a}^t \mathbf{x} + b > 0$$

para $\mathbf{a}$ y b apropiados.

Por lo tanto, las fronteras entre las clases es lineal.

Relación entre LDA y RL

En el modelo de Regresión Logística planteamos

$$\log \left(\frac{\mathbb{P}(Y = 1 \mid X = x)}{1 - \mathbb{P}(Y = 1 \mid X = x)} \right) = \mathbf{a}\mathbf{x} + b$$

o equivalentemente

$$\log \left(\frac{\mathbb{P}(Y = 1 \mid X = x)}{\mathbb{P}(Y = 0 \mid X = x)} \right) = \mathbf{a}\mathbf{x} + b$$

con lo cual comparar clasificaremos a un individuo en la clase 1 si $\mathbf{a}\mathbf{x} + b > 0$.

En RL estimamos $\mathbf{a}$ y b con otro procedimiento.

Cuando tenemos $M > 2$ grupos

La regla óptima asignará a un individuo con $\mathbf{X} = \mathbf{x}$ a la clase j que maximice:

$$f_j(\mathbf{x})p_j$$

En el caso normal con igual matriz de covarianza, maximizamos

$$\frac{\exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_j)^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}_j) \right\}}{(2\pi)^{p/2} [\det (\boldsymbol{\Sigma})]^{\frac{1}{2}}} p_j$$

Dado que el logaritmo es una función estrictamente creciente, podemos maximizar el logaritmo de esta expresión:

$$-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_j)^t \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu}_j) + \log p_j$$

Equivalentemente asignaremos a la clase j que maximiza

$$\mathbf{x}^t \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j - \frac{1}{2} \boldsymbol{\mu}_j^t \boldsymbol{\Sigma}^{-1} \boldsymbol{\mu}_j + \log p_j$$

Notemos que esto es una función lineal en $\mathbf{x}$.

Clasificación: Discriminación Cuadrática

Si cada $f_j \sim N(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)$, $j = 0, 1$, y no podemos asumir que las matrices de covarianza sean iguales, tenemos:

$$\frac{\exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_1)^t \boldsymbol{\Sigma}_1^{-1} (\mathbf{x} - \boldsymbol{\mu}_1) \right\}}{(2\pi)^{p/2} [\det(\boldsymbol{\Sigma}_1)]^{\frac{1}{2}}} p_1 \geq \frac{\exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_0)^t \boldsymbol{\Sigma}_0^{-1} (\mathbf{x} - \boldsymbol{\mu}_0) \right\}}{(2\pi)^{p/2} [\det(\boldsymbol{\Sigma}_0)]^{\frac{1}{2}}} p_0$$

Se clasifica en la clase 1 si

$$(\mathbf{x} - \boldsymbol{\mu}_1)^t \boldsymbol{\Sigma}_1^{-1} (\mathbf{x} - \boldsymbol{\mu}_1) - (\mathbf{x} - \boldsymbol{\mu}_0)^t \boldsymbol{\Sigma}_0^{-1} (\mathbf{x} - \boldsymbol{\mu}_0) + \log \frac{\det(\boldsymbol{\Sigma}_1)}{\det(\boldsymbol{\Sigma}_0)} + 2 \log \frac{p_0}{p_1} \leq 0$$

Clasificación: Discriminación Cuadrática

Si cada $f_j \sim N(\boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)$, $j = 0, 1$, y no podemos asumir que las matrices de covarianza sean iguales, tenemos:

$$\frac{\exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_1)^t \boldsymbol{\Sigma}_1^{-1} (\mathbf{x} - \boldsymbol{\mu}_1) \right\}}{(2\pi)^{p/2} [\det(\boldsymbol{\Sigma}_1)]^{\frac{1}{2}}} p_1 \geq \frac{\exp \left\{ -\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_0)^t \boldsymbol{\Sigma}_0^{-1} (\mathbf{x} - \boldsymbol{\mu}_0) \right\}}{(2\pi)^{p/2} [\det(\boldsymbol{\Sigma}_0)]^{\frac{1}{2}}} p_0$$

Se clasifica en la clase 1 si

$$(\mathbf{x} - \boldsymbol{\mu}_1)^t \boldsymbol{\Sigma}_1^{-1} (\mathbf{x} - \boldsymbol{\mu}_1) - (\mathbf{x} - \boldsymbol{\mu}_0)^t \boldsymbol{\Sigma}_0^{-1} (\mathbf{x} - \boldsymbol{\mu}_0) + \log \frac{\det(\boldsymbol{\Sigma}_1)}{\det(\boldsymbol{\Sigma}_0)} + 2 \log \frac{p_0}{p_1} \leq 0$$

Si graficamos esta región ya no queda una separación lineal entre las clases sino cuadrática ya que la expresión de arriba puede escribirse como:

$$\mathbf{x}^t \mathbf{A} \mathbf{x} + \mathbf{b}^t \mathbf{x} + c$$

Ahora: ¿Cómo estimamos a $\boldsymbol{\mu}_1, \boldsymbol{\mu}_0, \boldsymbol{\Sigma}_1$ y $\boldsymbol{\Sigma}_0$?

QDA: Cuando tenemos $M > 2$ grupos

En este caso QDA clasifica una observación en la clase c_j que maximiza

$$\mathbf{x}^t \mathbf{A}_j \mathbf{x} + \mathbf{b}_j^t \mathbf{x} + c_j$$

para $\mathbf{A}_j$, $\mathbf{b}_j$ y c_j apropiadas.

Ejemplo: Discriminación lineal y cuadrática

Vayamos al ejemplo de R.

Umbral de Clasificación

Como vimos la regresión logística devuelve una probabilidad estimada y podríamos dejarla como está o bien transformarla en un valor binario (0 ó 1, o bien P o N). ¿Con qué criterio?

Umbral de Clasificación

Como vimos la regresión logística devuelve una probabilidad estimada y podríamos dejarla como está o bien transformarla en un valor binario (0 ó 1, o bien P o N). ¿Con qué criterio?

Pensemos en la situación con covariable edad: si obtuviéramos para una determinada edad una probabilidad estimada de 0.99, seguramente asignaríamos a CUI, mientras que si fuera de 0.005 no lo haríamos....

Umbral de Clasificación

Como vimos la regresión logística devuelve una probabilidad estimada y podríamos dejarla como está o bien transformarla en un valor binario (0 ó 1, o bien P o N). ¿Con qué criterio?

Pensemos en la situación con covariable edad: si obtuviéramos para una determinada edad una probabilidad estimada de 0.99, seguramente asignaríamos a CUI, mientras que si fuera de 0.005 no lo haríamos....

...Y si para cierta edad la probabilidad estimada fuera 0.6 ¿a qué categoría la asignaríamos?

Umbral de Clasificación

Como vimos la regresión logística devuelve una probabilidad estimada y podríamos dejarla como está o bien transformarla en un valor binario (0 ó 1, o bien P o N). ¿Con qué criterio?

Pensemos en la situación con covariable edad: si obtuviéramos para una determinada edad una probabilidad estimada de 0.99, seguramente asignaríamos a CUI, mientras que si fuera de 0.005 no lo haríamos....

...Y si para cierta edad la probabilidad estimada fuera 0.6 ¿a qué categoría la asignaríamos?

Para asignar debemos tener un **umbral (threshold) de clasificación o decisión** por encima del cual asignamos a Positivo o 1 y por debajo del cual asignamos a N o 0.

Umbral de Clasificación

Como vimos la regresión logística devuelve una probabilidad estimada y podríamos dejarla como está o bien transformarla en un valor binario (0 ó 1, o bien P o N). ¿Con qué criterio?

Pensemos en la situación con covariable edad: si obtuviéramos para una determinada edad una probabilidad estimada de 0.99, seguramente asignaríamos a CUI, mientras que si fuera de 0.005 no lo haríamos....

...Y si para cierta edad la probabilidad estimada fuera 0.6 ¿a qué categoría la asignaríamos?

Para asignar debemos tener un **umbral (threshold) de clasificación o decisión** por encima del cual asignamos a Positivo o 1 y por debajo del cual asignamos a N o 0.

Muchas veces se supone a ese umbral como 0.5, pero este valor se debe ajustar en muchos problemas.

Verdadero Positivo y Falso Positivo

En un problema de aprendizaje supervisado, tenemos las etiquetas de cada individuo, por lo tanto podemos contrastar la asignación con la etiqueta.

De este contraste nos daremos cuenta de que existen asignaciones correctas y otras que no lo son. En base a esta información podemos computar distintas medidas para evaluar la performance de una clasificación.

Evaluación de la Clasificación: Métricas

- Matriz de Confusión
- Accuracy o Exactitud
- Sensibilidad
- Especificidad
- Curvas ROC

Matriz de confusión: Clasificación Binaria

Se trata de una tabla en la que se resume el rendimiento de un modelo de clasificación en los datos de prueba.

Su nombre se refiere a que permite identificar dónde el clasificador está confundiendo dos clases.

- **Verdaderos Positivos (VP)**: la clase real es Positiva ($=1$) y la predicha también es Positiva ($=1$)
- **Verdaderos Negativos (VN)**: la clase real es Negativa ($=0$) y la pronosticada también es Negativa ($=0$).
- **Falsos Positivos (FP)**: la clase real es Negativa ($=0$) y la pronosticada es Positiva ($=1$).
- **Falsos Negativos (FN)**: la clase real es Positiva ($=1$) y el valor predicho es Negativo ($=0$).

Matriz de Confusión

Observación	Predicción	
	+	-
● +	Verdaderos Positivos (VP)	Falsos Negativos (FN)
● -	Falsos Positivos (FP)	Verdaderos Negativos (VN)

Exactitud o Accuracy

La exactitud o accuracy es la proporción de clasificaciones correctas.

$$\frac{VP + VN}{VP + VN + FP + VN}$$

Es decir, es el número de predicciones correctas sobre el número de predicciones totales.

Exactitud o Accuracy

La exactitud o accuracy es la proporción de clasificaciones correctas.

$$\frac{VP + VN}{VP + VN + FP + VN}$$

Es decir, es el número de predicciones correctas sobre el número de predicciones totales.

No caracteriza a un buen clasificador necesariamente. Supongamos que tenemos 10 enfermos y 90 sanos y el clasificador, asigna a cualquier individuo a la clase sano. Entonces, la Accuracy sería 0.9.

No sirve si las clases están muy desbalanceadas.

Sensibilidad y Especificidad

- **Sensibilidad** (Recall)

$$\frac{VP}{VP + FN}$$

entre los positivos cuántos fueron predichos como positivos.
¿Qué proporción de positivos reales se identificó correctamente? Alta sensibilidad implica que no se deja a ningún positivo mal clasificado, pero ¿cómo se clasificaron los de la otra clase?

Ojo!: el clasificador que simplemente predice a todos como positivos tiene alta sensibilidad.

Sensibilidad y Especificidad

- **Sensibilidad** (Recall)

$$\frac{VP}{VP + FN}$$

entre los positivos cuántos fueron predichos como positivos.
¿Qué proporción de positivos reales se identificó correctamente? Alta sensibilidad implica que no se deja a ningún positivo mal clasificado, pero ¿cómo se clasificaron los de la otra clase?


Ojo!: el clasificador que simplemente predice a todos como positivos tiene alta sensibilidad.

- **Especificidad**


$$\frac{VN}{VN + FP}$$

entre los negativos cuántos fueron predichos negativos. Mide la capacidad de detectar negativos.

Especificidad vs. Sensibilidad



Especificidad vs. Sensibilidad



Curvas ROC


Curvas ROC

- ROC es un acrónimo para **Receiver Operating Characteristic**.
- Las curvas ROC fueron desarrolladas durante la 2da. Guerra Mundial en el campo de detección de señales para analizar la capacidad de un operador de radar para detectar un objeto enemigo en la pantalla y distinguirlo de simple ruido.
- Son una herramienta gráfica para medir la exactitud de un método de clasificación.
- Se popularizaron mucho a partir de los 70's en Medicina.

Sanos

Enfermos

Biomarcador



Curvas ROC: caso poblacional

- **Problemas de Clasificación:** una variable continua o **marcador Y** es usado para clasificar un individuo en uno de dos estados: **Positivo (1)** o **Negativo (0)** de acuerdo a un **valor crítico c** .
- Un nuevo sujeto es clasificado como
 - 1: Positivo si $W \geq c$
 - 0: Negativo si $W < c$
- Distribución de Y
 - $W \sim F_1$ en la Población de Positivos
 - $W \sim F_0$ en la Población de Negativos
- Las curvas ROC representan la capacidad del clasificador binario para asignar un individuo a su clase a medida que variamos c .

Curvas ROC - W : marcador (v.a continua)

- Para cada **constante c** , habrá individuos positivos que serán clasificados como negativos y viceversa $\rightarrow$
 - **Verdaderos Positivos (VP)** y **Verdaderos Negativos (VN)**
 - **Falsos Positivos (FP)** y **Falsos Negativos (FN)**

Curvas ROC - W : marcador (v.a continua)

- Para cada **constante c** , habrá individuos positivos que serán clasificados como negativos y viceversa $\rightarrow$
 - **Verdaderos Positivos (VP)** y **Verdaderos Negativos (VN)**
 - **Falsos Positivos (FP)** y **Falsos Negativos (FN)**
- Estamos interesados en
 - Habilidad de detectar positivos

$$\text{Sensibilidad} = 1 - F_1(c)$$

- Habilidad de asignar correctamente a los sujetos negativos

$$\text{Especificidad} = F_0(c)$$

Curvas ROC - W : marcador (v.a continua)

- La curva ROC representa

$$\text{Sensibilidad} = 1 - F_1(c) \quad \text{vs.} \quad 1 - \text{Especificidad} = 1 - F_0(c)$$

según varía **el valor crítico c** .

Curvas ROC - W : marcador (v.a continua)

- La curva ROC representa

$$\text{Sensibilidad} = 1 - F_1(c) \quad \text{vs.} \quad 1 - \text{Especificidad} = 1 - F_0(c)$$

según varía **el valor crítico c** .

- Curva ROC:** si reparametrizamos en función de la fracción de falsos positivos: $p = 1 - F_0(c)$


$$ROC(p) = 1 - F_1 \left(F_0^{-1}(1 - p) \right), \quad p \in (0, 1).$$

Curva ROC

Definiciones

- Curva ROC:


$$ROC(p) = 1 - F_1 \left(F_0^{-1}(1 - p) \right), \quad p \in (0, 1).$$



Definiciones

- ROC Curve:

$$ROC(p) = 1 - F_1(F_0^{-1}(1 - p)), \quad p \in (0, 1).$$



- AUC: Índice de resumen que mide el **área bajo la curva ROC**




$$AUC = \int_0^1 ROC(p) dp = \mathbb{P}(Y_1 > Y_0).$$

- YI: Índice de Youden, mide la diferencia entre la curva ROC y la identidad


$$YI = \max_{0 < p < 1} \{ROC(p) - p\}.$$

Curva ROC + AUC

Marcador No informativo



Marcador Perfecto



$$ROC(p) = 1 - F_D(F_H^{-1}(1 - p))$$

Curvas ROC: con los datos

$$\text{Tasa de Verdaderos Positivos (TPR)} = \frac{VP}{VP + FN} = \text{Sensibilidad}$$

(TPR: True Positive Ratio)

Curvas ROC: con los datos

$$\text{Tasa de Verdaderos Positivos (TPR)} = \frac{VP}{VP + FN} = \text{Sensibilidad}$$

(TPR: True Positive Ratio)

$$\text{Tasa de Falsos Positivos (FPR)} = \frac{FP}{FP + VN} = 1 - \text{Especificidad}$$

(FPR: False Positive Ratio)

Curvas ROC: con los datos

$$\text{Tasa de Verdaderos Positivos (TPR)} = \frac{VP}{VP + FN} = \text{Sensibilidad}$$


(TPR: True Positive Ratio)

$$\text{Tasa de Falsos Positivos (FPR)} = \frac{FP}{FP + VN} = 1 - \text{Especificidad}$$


(FPR: False Positive Ratio)

Una curva ROC representa TPR vs. FPR en diferentes umbrales de clasificación.


Especificidad vs. Sensibilidad



Especificidad vs. Sensibilidad



Especificidad vs. Sensibilidad



Curvas ROC

¿Con qué umbral nos quedamos?

Se suele elegir el Índice de Youden:

máximo de (sensibilidad + especificidad - 1).

Vayamos a un ejemplo: datos de COVID


Usamos los datos oficiales suministrados por el Ministerio de Salud hasta el 09-07-2020.

Consideramos los casos confirmados de adultos entre 20 y 70 años y las variables Variables:

- **cui:** cuidados intensivos (1=si o 0=no)
- **edad**
- **género:** F (1) o M (0)


Explorando Efectos

Género F




CUI

Género M



CUI



Algunas medidas de resumen

```
> table(sexo)
```

```
sexo
```

```
F      M
```

```
34251 36731
```

```
> table(cuidado_intensivo)
```

```
cuidado_intensivo
```

```
NO      SI
```

```
69853  1129
```

```
> summary(edad.dec)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
20.00	29.00	38.00	39.56	49.00	69.00

ROC: usando Edad y Género

```
#fije semilla
dima<-dim(datos)
grupo.train<- sample(c(0,1), dima[1], replace = TRUE, prob=c(0.10,0.90))
indices<- 1:dima[1]
indices.train<- (indices[grupo.train==1])

datos.train<- datos[indices.train,]
datos.test<- datos[-indices.train,]

mean(datos.train$cui)
mean(datos.test$cui)
mean(datos$cui)


salida.train<- glm(cui~edad.dec+genero, data=datos.train, family=binomial)
predicciones<-predict.glm(salida.train, datos.test, type="response")

library(ROCR)
predict.rocr<- prediction(predicciones, datos.test$cui)
pref.rocr<- performance(predict.rocr, "tpr", "fpr")

auc.cui<- as.numeric(performance(predict.rocr, "auc")@y.values)
auc.cui

plot(pref.rocr, colorize=TRUE, type="l", main=paste("AUC=", round(auc.cui, 2)))
abline(a=0, b=1)
```

Curva ROC



Support Vector Machine: SVM

SVM

- Este es una propuesta desarrollada en la comunidad de Ciencias de la Computación: Vladimir Vapnik y colegas en los 90's.
- Ha mostrado funcionar muy bien en distintos escenarios: fronteras lineales y no lineales.
- Es una generalización de lo que se conoce como *maximal margin classifier*

Support Vector Machine

Las observaciones que determinan el maximal margin hyperplane se les conoce como vectores soporte.



Muchas veces los datos no se pueden separar linealmente de forma perfecta, por lo que no existe un hiperplano de separación.

Una estrategia en los que la separación de los grupos es de tipo no lineal consiste en expandir las dimensiones del espacio original.

El hecho de que los grupos no sean linealmente separables en el espacio original no significa que no lo sean en un espacio de mayores dimensiones.


Support Vector Machine

Por ejemplo




Support Vector Machine

O bien,




X1



Maximal Margin Classifier

Como antes tendremos una matriz de datos de $n \times p$ $\mathbf{X}$ que consiste en nuestros n datos de entrenamiento que caen en dos clases: $\{-1, 1\}$ que se registran en las respuestas $Y_1, \dots, Y_n$.




Maximal Margin Classifier

Caso Separable

Supongamos que es posible construir un hiperplano que separe las observaciones de entrenamiento perfectamente a un lado y otro del hiperplano de acuerdo con sus etiquetas de clase.

En el gráfico vemos 3 de estos hiperplanos separadores.

Etiquetamos las observaciones de la clase azul como $y_i = 1$ y por otro lado, las de la clase magenta como $y_i = -1$.




Maximal Margin Classifier

Caso Separable

Supongamos que es posible construir un hiperplano que separe las observaciones de entrenamiento perfectamente a un lado y otro del hiperplano de acuerdo con sus etiquetas de clase.

En el gráfico vemos 3 de estos hiperplanos separadores.

Etiquetamos las observaciones de la clase azul como $y_i = 1$ y por otro lado, las de la clase magenta como $y_i = -1$.



¿Qué hiperplano elegimos?

Maximal Margin Classifier

Bajo separación perfecta

Un hiperplano separador cumple:

$$\beta^t \mathbf{x}_i + \beta_0 > 0 \text{ si } y_i = 1$$

$$\beta^t \mathbf{x}_i + \beta_0 < 0 \text{ si } y_i = -1$$


o equivalentemente $y_i(\beta^t \mathbf{x}_i + \beta_0) > 0, i = 1, \dots, n$.

Esto nos llevaría a un clasificador del tipo: $\text{sgn}(\beta^t \mathbf{x}_i + \beta_0)$

Lo que se conoce como el **maximal margin hyperplane** (u *optimal separating hyperplane*) es el separador que está más lejos de las observaciones de training.

Maximal Margin Classifier

Podemos calcular la distancia perpendicular de cada observación a un hiperplano de separación dado; la distancia más pequeña de este tipo se conoce como **margin** (o margen). El **maximal margin hyperplane** es el hiperplano de separación para el cual el margen es mayor, o sea es el hiperplano que tiene la mayor distancia mínima a las observaciones de entrenamiento.



- Margen: mínima distancia de los puntos al hiperplano
- Margen: representa el margen de error del clasificador, si el margen es ancho la muestra test será clasificada más probablemente en forma correcta
- Maximal Margin Hyperplane
- Vectores de soporte

Margen

Formalmente, decimos que las clases son linealmente separables si existen β y β_0 tales que $y_i z(\mathbf{x}_i) > 0$, para todo punto en la muestra de entrenamiento, siendo $z(\mathbf{x}) = \beta^t \mathbf{x} + \beta_0$.

Dado un punto $\mathbf{x}$ consideremos su proyección ortogonal a la frontera definida por un hiperplano separador $\beta^t \mathbf{x} + \beta_0 = 0$: $\mathbf{x}^*$.

Observemos que:

- $\mathbf{x}^*$ cumple: $\beta^t \mathbf{x}^* + \beta_0 = 0$
- $(\mathbf{x} - \mathbf{x}^*)$ es ortogonal a hiperplano, cuyo vector normal es β
- $|\beta^t(\mathbf{x} - \mathbf{x}^*)| = \|\beta\| \|\mathbf{x} - \mathbf{x}^*\|$
- $\beta^t(\mathbf{x} - \mathbf{x}^*) = \beta^t(\mathbf{x} - \mathbf{x}^* \pm \beta_0) = z(\mathbf{x})$
- Por lo tanto: $\|\mathbf{x} - \mathbf{x}^*\| = \frac{|z(\mathbf{x})|}{\|\beta\|}$
- Luego para cada punto de la muestra tenemos que la distancia es:

$$\frac{|z(\mathbf{x}_i)|}{\|\beta\|} = \frac{y_i z(\mathbf{x}_i)}{\|\beta\|}$$

Margen

$$M = M(\beta, \beta_0) = \min_i \frac{y_i z(\mathbf{x}_i)}{\|\beta\|} = \frac{1}{\|\beta\|} \min_i y_i (\beta^t \mathbf{x}_i + \beta_0) = \frac{y_\ell (\beta^t \mathbf{x}_\ell + \beta_0)}{\|\beta\|}$$

Queremos maximizar el margen $M(\beta, \beta_0)$ sujeto a que $y_i z(\mathbf{x}_i) > 0, i = 1, \dots, n$

El problema de maximizar el margen M puede escribirse como:

$$\operatorname{argmax}_{\beta, \beta_0} \left\{ \frac{1}{\|\beta\|} \min_i \{y_i (\beta^t \mathbf{x}_i + \beta_0)\} \right\}$$

Margen

$$M = M(\beta, \beta_0) = \min_i \frac{y_i z(\mathbf{x}_i)}{\|\beta\|} = \frac{1}{\|\beta\|} \min_i y_i (\beta^t \mathbf{x}_i + \beta_0) = \frac{y_\ell (\beta^t \mathbf{x}_\ell + \beta_0)}{\|\beta\|}$$

Queremos maximizar el margen $M(\beta, \beta_0)$ sujeto a que
 $y_i z(\mathbf{x}_i) > 0, i = 1, \dots, n$


El problema de maximizar el margen M puede escribirse como:

$$\operatorname{argmax}_{\beta, \beta_0} \left\{ \frac{1}{\|\beta\|} \min_i \{y_i (\beta^t \mathbf{x}_i + \beta_0)\} \right\}$$

como suele escribirse en general:


$$\begin{aligned} & \max_{\beta, \beta_0, \|\beta\|=1} M \\ & \text{sujeto a} \\ & y_i (\beta^t \mathbf{x}_i + \beta_0) \geq M, \quad i = 1, \dots, n \end{aligned}$$

Margen: caso separable



- Clasificación: $\text{sgn}(\beta^t \mathbf{x}_i + \beta_0)$
- Vectores Soporte: son los puntos que satisfacen $y_i (\beta^t \mathbf{x}_i + \beta_0) = M$
- La solución depende de estos puntos

Caso No Separable



Caso No Separable

El problema de maximizar ahora es:

$$\begin{aligned} & \max_{\beta, \beta_0, \epsilon_i} M \\ & \text{sujeto a} \\ & \|\beta\| = 1 \\ & y_i (\beta^t \mathbf{x}_i + \beta_0) \geq M(1 - \epsilon_i), \quad i = 1, \dots, n \\ & \epsilon_i \geq 0, \quad \sum_{i=1}^n \epsilon_i \leq C, \quad C > 0 \end{aligned}$$

donde C representa el costo.

C es un hiperparámetro que es *data-driven*.

Observaciones

- Regla de Clasificación: $\text{sgn}(\beta^t \mathbf{x}_i + \beta_0)$
- El caso anterior corresponde a $\epsilon_i = 0$, pero ahora no existe solución con esta condición.
- ¿a qué corresponde $0 < \epsilon_i \leq 1$?

Observaciones


- Regla de Clasificación: $\text{sgn}(\beta^t \mathbf{x}_i + \beta_0)$
- El caso anterior corresponde a $\epsilon_i = 0$, pero ahora no existe solución con esta condición.
- ¿a qué corresponde $0 < \epsilon_i \leq 1$? dato dentro del margen bien clasificado
- ¿ $1 < \epsilon_i$?

Observaciones


- Regla de Clasificación: $\text{sgn}(\beta^t \mathbf{x}_i + \beta_0)$
- El caso anterior corresponde a $\epsilon_i = 0$, pero ahora no existe solución con esta condición.
- ¿a qué corresponde $0 < \epsilon_i \leq 1$? dato dentro del margen bien clasificado
- ¿ $1 < \epsilon_i$? corresponde a dato mal clasificado

Aquí estamos dispuestos a *sacrificar* observaciones para poder clasificar bien a las demás.

Caso No Separable



Generalización a fronteras no lineales



Generalización a fronteras no lineales

El clasificador que hemos visto encuentra fronteras lineales. Como con otros procedimientos lineales podemos hacerlo más flexible ampliando el espacio de las variables incorporando otras funciones, como polinomios o splines. Ampliando el espacio de covariables, el método se vuelve flexible y se adapta a fronteras no lineales.

Esto se logra mediante la función $z(\mathbf{x})$.

Elegimos M funciones $\phi_1(\mathbf{x}), \dots, \phi_M(\mathbf{x})$.

Procedemos como antes, pero ahora tomamos

$\phi(\mathbf{x}) = (\phi_1(\mathbf{x}), \dots, \phi_M(\mathbf{x}))$: en lugar de $z(\mathbf{x}) = \beta^t \mathbf{x} + \beta_0$ consideramos:
 $z(\mathbf{x}) = \beta^t \phi(\mathbf{x}) + \beta_0$

Teniendo en cuenta el Lagrangiano dual, se puede ver que $z(\mathbf{x})$ está determinada por productos internos en el espacio transformado:

$$\sum_{i=1}^n \alpha_i y_i \langle \phi(\mathbf{x}), \phi(\mathbf{x}_i) \rangle + \beta_0$$

Dados los α_i β_0 es se puede determinar a partir de las observaciones para las cuales $0 < \alpha_i < C$.

Kernels

Lo que se necesita especificar son los kernels o núcleos de la forma:

$$K(\mathbf{x}, \mathbf{x}') = \langle \phi(\mathbf{x}), \phi(\mathbf{x}') \rangle$$

que calcula los productos internos en el espacio transformado.

K en general es una función positiva simétrica.

Polinomios grado d : $K(x, x') = (1 + \langle x, x' \rangle)^d$,

Radial: $K(x, x') = \exp\left(-\gamma \|x - x'\|^2\right)$,

Tangente Hip.: $K(x, x') = \tanh(\kappa_1 \langle x, x' \rangle + \kappa_2)$.

Kernels: Ejemplo

Consideremos para un espacio bidimensional con variables X_1 y X_2 , un núcleo de grado 2: $\mathbf{X} = (X_1, X_2)$ y $\mathbf{X}' = (X'_1, X'_2)$

$$\begin{aligned}K(\mathbf{X}, \mathbf{X}') &= (1 + \langle \mathbf{X}, \mathbf{X}' \rangle)^2 \\&= (1 + X_1 X'_1 + X_2 X'_2)^2 \\&= 1 + 2X_1 X'_1 + 2X_2 X'_2 + (X_1 X'_1)^2 + (X_2 X'_2)^2 + 2X_1 X'_1 X_2 X'_2\end{aligned}$$

Sea $M = 6$, si elegimos

$\phi_1(\mathbf{X}) = 1, \phi_2(\mathbf{X}) = \sqrt{2}X_1, \phi_3(\mathbf{X}) = \sqrt{2}X_2, \phi_4(\mathbf{X}) = X_1^2, \phi_5(\mathbf{X}) = X_2^2,$
y $\phi_6(\mathbf{X}) = \sqrt{2}X_1 X_2$, tenemos:

$(1, \sqrt{2}X_1, \sqrt{2}X_2, X_1^2, X_2^2, \sqrt{2}X_1 X_2)(1, \sqrt{2}X'_1, \sqrt{2}X'_2, X_1'^2, X_2'^2, \sqrt{2}X'_1 X'_2)'$
luego $K(\mathbf{X}, \mathbf{X}') = \langle \phi(\mathbf{X}), \phi(\mathbf{X}') \rangle$.